

МИНОБРНАУКИ РОССИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«БЕЛГОРОДСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНОЛОГИЧЕСКИЙ
УНИВЕРСИТЕТ им. В.Г. ШУХОВА»
(БГТУ им. В.Г. Шухова)

Институт информационных технологий и управляющих систем

Кафедра программного обеспечения вычислительной техники и автоматизированных систем

Направление подготовки 09.03.04 Программная инженерия

Направленность (профиль) образовательной программы Разработка программно-информационных систем

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

на тему:

**Реализация алгоритма извлечения звука
музыкального инструмента из звукового потока
на основе методов искусственного интеллекта**

Студент (ка): Барышникова Варвара Дмитриевна

Зав. кафедрой: канд. техн. наук, доц. Поляков Владимир Михайлович

Руководитель: канд. физ.-мат. наук, доц. Осипов Олег Васильевич

К защите допустить

Зав. кафедрой _____ /Поляков В.М./

« _____ » _____ 2026 г.

Белгород 2026 г.

МИНОБРНАУКИ РОССИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«БЕЛГОРОДСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНОЛОГИЧЕСКИЙ
УНИВЕРСИТЕТ им. В.Г. ШУХОВА»
(БГТУ им. В.Г. Шухова)

Институт информационных технологий и управляющих систем

Кафедра программного обеспечения вычислительной техники и автоматизированных систем

Направление подготовки 09.03.04 Программная инженерия

Направленность (профиль) образовательной программы Разработка программно-информационных систем

Утверждаю:

Зав. кафедрой _____

«_____» _____ 2026 г.

ЗАДАНИЕ

на выпускную квалификационную работу студента (ки)

Иванова Ивана Ивановича

1. Вид выпускной квалификационной работы (ВКР): *бакалаврская работа*.
2. Тема ВКР *Разработка программного обеспечения для прогнозирования погоды на основе анализа спутниковых снимков с использованием методов машинного обучения* утверждена приказом по университету от «28» января 2026 г. №2/124.
3. Срок сдачи студентом (кой) законченной ВКР: «12» июня 2026 г.
4. Исходные данные: ключевые слова, название алгоритмов и методов, технологии разработки и т.п. Пример: рекомендательные системы, подходы построения рекомендательных систем, методы матричной факторизации, оптимизационные методы обучения модели, аффинные преобразования, трёхмерная графика, машинное обучение, клиент-серверное приложение, генеративная нейронная сеть.
5. Содержание ВКР: Здесь должны быть перечислены названия разделов (глав) пояснительной записки. Пример:
 - Введение,
 - Описание предметной области прогнозирования погоды,
 - Разработка архитектуры программного обеспечения прогнозирования погоды,
 - Разработка алгоритмов и программного обеспечения прогнозирования погоды,
 - Тестирование программной системы прогнозирования погоды,
 - Руководство пользователя разработанной системы прогнозирования погоды,
 - Заключение,
 - Список литературы,
 - Приложение А,
 - Приложение Б.

6. Перечень графического материала: 1278 рисунков, 1785 таблиц. Презентация включает: постановку задачи, актуальность, технологии, численные эксперименты, внешний вид программы, заключение.

Консультанты по работе с указанием относящихся к ним разделов:

Раздел	Консультант	Задание выдал (подпись, дата)	Задание принял (подпись, дата)

Дата выдачи задания: «17» января 2026 г.

(подпись руководителя)

Задание принял (приняла) к исполнению

(подпись студента (ки))

КАЛЕНДАРНЫЙ ПЛАН

№ п/п	Наименование этапов работы	Срок выполнения этапов работы	Примечание
1	Анализ предметной области. Постановка задачи разработки системы прогнозирования погоды методами машинного обучения.	18.01.26 – 15.02.26	Выполнено
2	Разработка алгоритмов, структур нейросетей и архитектуры системы прогнозирования погоды.	15.02.26 – 20.03.26	Выполнено
3	Разработка программной части системы прогнозирования погоды.	20.03.26 – 29.03.26	Выполнено
4	Разработка клиентской части системы прогнозирования погоды.	29.03.26 – 29.04.26	Выполнено
5	Тестирование программного обеспечения для прогнозирования погоды.	29.04.26 – 17.05.26	Выполнено
6	Оформление пояснительной записки. Подготовка выступления.	17.05.26 – 10.06.26	Выполнено
5	Тестирование программного обеспечения для прогнозирования погоды.	29.04.26 – 17.05.26	Выполнено
6	Оформление пояснительной записки. Подготовка выступления.	17.05.26 – 10.06.26	Выполнено

Студент (ка) _____ *Иванов Иван Иванович*
(подпись) (Ф.И.О.)

Руководитель _____ *Осипов Олег Васильевич*
(подпись) (Ф.И.О.)

Результаты проверки ЭВ ВКР на заимствование

Кафедра программного обеспечения вычислительной техники и автоматизированных систем

Студент (ка) Иванов И.И. ПВ-212 16.06.2026
(Ф.И.О.) (подпись) (группа) (дата)

Тема ВКР: Разработка программного обеспечения для прогнозирования погоды на основе анализа спутниковых снимков с использованием методов машинного обучения.

ВКР прошла проверку на объём заимствований.

Итоговая оценка заимствований: **3,1415926535897932384626433832%.**

Работу проверил _____ 16.06.2026 Хлопов А.М.
(подпись) (дата) (Ф.И.О.)

Руководитель ВКР

канд. соц. наук, доцент	16.06.2026	Островский А.М.
(уч. степень, должность)	(подпись)	(Ф.И.О.)

ОПРЕДЕЛЕНИЯ, СОКРАЩЕНИЯ И ОБОЗНАЧЕНИЯ

Стем (от англ. stem – «основа») – единица музыкального аудиопотока в задаче извлечения источников. Представляет собой запись отдельного типа музыкального инструмента или вокала в исходной многокомпонентной музыкальной аудиозаписи.

SiSec 2018 (Signal Separation Evaluation Campaign) – кампания по оценке разделения сигналов 2018 года.

SiSec 2018 MUS – задача, которая решалась во время кампании SiSec 2018. Задача состояла в оценке систем, которые извлекают музыкальные инструменты из популярных музыкальных аудиопотоков, миксов.

MUSDB18 – датасет музыкальных композиций с разделенными стемами, который был составлен в рамках задачи SiSec 2018 MUS.

MSS (music source separation) – задача выделения источников из музыкального потока.

SOTA (state of art) – ”состояние искусства стандарт, признанный в исследовательской среде в рамках какой-либо исследовательской задачи.

MSST-WebUI (Music-Source-Separation-Training WebUI) – веб-интерфейс, который объединяет множество современных моделей разделения источников.

BSS Eval – Blind Source Separation Evaluation.

SDR (Signal to Distortion Ratio) – система управления базами данных.

SIR (source to interference ratio) – объектно-ориентированное программирование.

SAR (sources to artifacts ratio) – .

mir_eval — это Python-библиотека, которая предоставляет стандартизированный и простой способ оценки систем обработки музыкальной информации (Music Information Retrieval, MIR). Она включает реализацию распространённых метрик для различных задач в области MIR.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	6
1 АНАЛИЗ СОСТОЯНИЯ ИССЛЕДОВАНИЯ В ОБЛАСТИ ИЗВЛЕЧЕНИЯ ИСТОЧНИКОВ	7
1.1 Вклад кампании SiSEC MUS 2018 в задачу разделения источников	8
1.2 Способы представления звука для задачи разделения источников	8
1.3 Обзор архитектур разделения источников	8
1.3.1 Классические методы source separation	8
1.3.2 Современные нейронные архитектуры	8
1.4 Анализ методов дообучения предобученных моделей разделения источников	17
1.4.1 Полное дообучение	18
1.4.2 Методы «параметрического» дообучения (адаптация части параметров)	18
1.4.3 Адаптация низкого ранга (LoRA, Low Rank Adaptation)	19
1.5 Функции потерь	22
1.6 Метрики оценки качества (SDR, SIR, SAR)	22
1.6.1 Декомпозиция сигнала по методу BSS Eval	22
1.6.2 Масштабно-инвариантная метрика (SI-SDR)	24
2 Разработка архитектуры программного обеспечения	25
2.0.1 Выбор базовой модели среди существующих для извлечения конкретных инструментов	25
2.1 Выбор способа дообучения	25
3 Разработка алгоритмов и программного обеспечения	27
ЗАКЛЮЧЕНИЕ	28
СПИСОК ЛИТЕРАТУРЫ	29

ВВЕДЕНИЕ

- Актуальность задачи извлечения инструментов
- Цель работы: адаптация модели Demucs для улучшения качества извлечения гитары
- Задачи исследования

Актуальность (музыкальное ADR, мастеринг, ремиксы, авторские права и т.п.).

Объект, предмет, цель, задачи, научная новизна.

Задача: Адаптация лёгких архитектур для извлечения гитары и пианино из полифонических композиций с учётом спектрального перекрытия (Частотно-временное перекрытие) и последующего восстановления тембрового качества.

1 АНАЛИЗ СОСТОЯНИЯ ИССЛЕДОВАНИЯ В ОБЛАСТИ ИЗВЛЕЧЕНИЯ ИСТОЧНИКОВ

Выделение аудио-источников (Audio Source Separation) — процесс разделения индивидуальных источников звука в смешанном аудиосигнале. Цель такой задачи — выделить конкретные источники, например вокал, инструменты или фоновый шум, из сложной аудиозаписи (Рисунок 1.1).

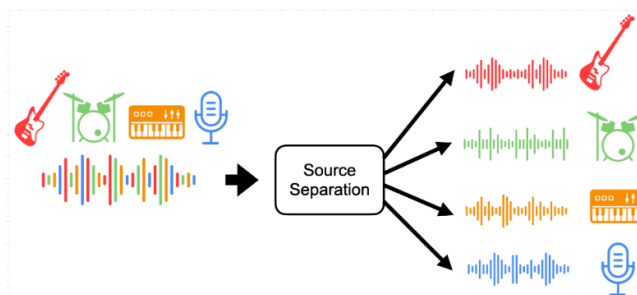


Рисунок 1.1 – Упрощенный процесс разделения источников из аудиозаписи.

Источник

Для разделения используются алгоритмы обработки сигналов, которые используют различные техники: спектральный анализ, анализ во временной и частотной областях, машинное обучение.

Итогом выполнения задачи декомпозиции смешанного аудиосигнала является входные данные в виде составляющих компонент, называемых стемами (дорожками) [2]. Стем (от англ. stem – «основа») является единицей музыкального аудиопотока. Когда происходит запись в студии звукозаписи, например, музыкального трека, то происходит запись отдельных музыкальных инструментов и вокала (стемов) и образуется финальная композиция, песня. И цель задачи извлечения сигналов, в том, чтобы воссоздать эти индивидуальные стеми из смешанного сигнала-музыкальной дорожки. [3]

Притом, такая задача подразумевает получение из одного аудиотрека (аудиопотока) несколько источников (то есть задача сложнее, чем из потока шума получить какой-то один источник – в статье [3] приводится пример появления задачи – потребность услышать и вычленить из общего шума коктейльной вечеринки голос и рассказ своего собеседника). Тогда можно считать, что исходный музыкальный трек состоит из стемов, и каждый из них можно извлечь из него.

Поэтому необходимо провести обзор методов разделения музыкальных источников, а также методы дообучения нейросетей.

1.1 Вклад кампании SiSEC MUS 2018 в задачу разделения источников

В статье о реализации нейронной сети Open-Unmix [2] говорится про кампанию по оценке разделения сигналов 2018 года (SiSEC 2018 – Signal Separation Evaluation Campaign) [4] [5]. В рамках этой кампании решалась задача SiSEC MUS (оценка систем, которые извлекают музыкальные инструменты из популярных музыкальных аудиопотоков, миксов (mix – смесь)) такие стемы были сгруппированы в общие категории :

- барабаны (drums),
- бас (bass),
- вокал (vocals),
- другие музыкальные инструменты и звуки (other).

В результате кампании SiSEC Mus 2018 был выпущен датасет MUSDB18 [6] [7], содержащий 150 музыкальных композиций с разделенными стемами в сумме составляющие 10-часовой плейлист. MUSDB18 и по сей день является самым большим бесплатным датасетом в открытом доступе и активно используется в задачах дообучения нейронных сетей, решающих задачу разделения источников [2] (при необходимости или скудности материалов этого датасета исследователи прибегают к самостоятельному сбору специфичных датасетов [8]).

1.2 Способы представления звука для задачи разделения источников

1.3 Обзор архитектур разделения источников

1.3.1 Классические методы source separation

ICA

NMF

спектральные методы

1.3.2 Современные нейронные архитектуры

Современные архитектуры MSS (music source separation) можно условно разделить на два основных класса в зависимости от того, в какой области они обрабатывают аудиосигнал: во временной области (Demucs [3]) или в частотной (Open-Unmix [2] и Spleeter). Далее рассмотрим эти основные виды архитектур и сравним их способы реализации и применение.

Архитектуры, которые представляют собой SOTA (state of art)////////////////////////////////////

Demucs

В статье [1] разработчики соц сети Facebook описывают новый подход к методу source separation. Demucs (Hybrid Transformer Demucs) на данный момент является одним из стандартов индустрии (SOTA) задачи извлечения источников.

Demucs [1] – это нейронная сеть глубокого обучения, которая была разработана для решения задачи выделения аудио-источников. В основе нейросети Demucs лежит свёрточная нейронная сеть UNet [2], которая используется для семантической сегментации изображений. То есть Demucs использует подход сети Unet обработки изображений и применяет для обработки волн аудиосигнала по спектрограммам [1].

В статье музыкальная композиция сравнивается с коктейльной вечеринкой, где каждый голос, фоновая мелодия и шум – каждый этот элемент является стемом, и тогда задача выделения голоса собеседника, с которым ведется диалог на вечеринке, является как раз задачей разделения источников. Но задача выделения источников из музыкальной композиции отличается от задачи выделения голоса собеседника на коктейльной вечеринке в первую очередь тем, что в ней интересует в этой задаче выделение не какого-то одного приоритетного источника звука из несвязанного фонового шума, а целый набор тонов и тембров в согласованном потоке.

Авторы утверждают, что на момент постановки проблемы этой статьи основные современные методы извлечения источника оперируют анализом спектрограмм, которые генерируются на основе кратковременного преобразования Фурье (short-time Fourier transform, STFT) [3] [4].

Метод основан на создании маски для magnitude spectrums for each frame and each source, and the output audio is generated by running an inverse STFT on the masked spectrograms reusing the input mixture phase.

Разработчики Demucs основываются на архитектуре Conv-Tasnet и адаптируют ее под извлечение источников (source separation).

Модель Demucs (в актуальных версиях v3/v4 [1] [5]) представляет собой гибридную архитектуру, объединяющую сверточные нейронные сети (CNN) и трансформеры для обработки аудиосигнала во временной области. Основная идея заключается в прямом моделировании звуковой волны, что позволяет избежать артефактов, возникающих при обратном преобразовании Фурье.

Модель Demucs состоит из следующих основных компонент:

- 1) Гибридный энкодер (Hybrid Encoder). Входной сигнал $x(t)$ преобразуется в скрытое представление (латентные признаки) с помощью одномерных сверточных слоев (1D Convolution). В отличие от чистых временных мо-

делей, Demucs также извлекает признаки из спектрограммы (STFT) того же сигнала. Это позволяет модели использовать преимущества обеих областей: временную точность и частотную структуру.

- 2) Блок разделения (Separator / Transformer). Полученные признаки подаются на вход слоя, состоящего из Transformer-блоков. В отличие от LSTM в Open-Unmix, механизм «самовнимания» (Self-Attention) позволяет модели захватывать глобальный контекст всей композиции, эффективно разделяя источники с длинными зависимостями. Внутри блока применяется маскирование или прямое оценивание источников.
- 3) Гибридный декодер (Hybrid Decoder). Разделенные латентные представления преобразуются обратно в звуковую волну с помощью транспонированных одномерных сверток (Transposed Convolution). Декодер также работает в двух доменах: он восстанавливает временной сигнал и частотное представление, которые затем суммируются.
- 4) Гибридная функция потерь (Hybrid Loss). Обучение оптимизирует ошибку одновременно в двух областях: во временной (L1/L2 loss) и частотной (L1/L2 loss по спектрограмме). Это заставляет модель генерировать сигнал, который звучит естественно (временная область) и имеет правильную спектральную структуру (частотная область).

Модели, работающие во временной области, такие как Demucs, обрабатывают аудиосигнал непосредственно в виде последовательности амплитудных значений (волн). Их главное преимущество заключается в сохранении полной информации о сигнале, включая фазовые характеристики, что критически важно для точного воспроизведения резких атак нот, характерных для многих инструментов, включая гитару и ударные.

Также к преимуществам модели Demucs относятся:

- 1) Высокое качество разделения (SOTA). Demucs демонстрирует одни из лучших результатов на бенчмарках (MUSDB18, FSD50k), превосходя LSTM-подходы (Open-Unmix) по метрикам SDR (Signal-to-Distortion Ratio) и SAR (Signal-to-Artifact Ratio).
- 2) Глобальный контекст (Transformer). Использование механизма самовнимания позволяет учитывать структуру музыкального произведения на больших промежутках времени, эффективно разделяя источники с похожими тембрами.
- 3) Гибридная оптимизация. Совместное обучение на временных и частотных потерях обеспечивает баланс между восприятием сигнала на слух и точностью спектрального разделения.

Но у модели Demucs также есть значительные ограничения, которые создают препятствия по использованию модели в исследовательских работах:

- 1) Вычислительная сложность. Архитектура Transformer имеет квадратичную сложность $O(N^2)$ по отношению к длине последовательности, что требует значительных ресурсов видеопамяти (VRAM) и времени для инференса по сравнению с Open-Unmix.
- 2) Большое количество параметров. Demucs v4 содержит сотни миллионов параметров, что затрудняет развертывание модели на мобильных устройствах или встраиваемых системах без дополнительных методов компрессии.
- 3) Галлюцинации (Artifacts). В случаях при сильном перекрытии источников трансформер может генерировать несуществующие звуковые артефакты (hallucinations), пытаясь «заполнить» пробелы в спектре.

U-Net на спектрограммах (???)

Conv-TasNet-подобные

Open-Unmix Существуют модели, работающие в частотной области, такие как Open-Unmix [6] и Spleeter. Такие модели сначала преобразуют аудиосигнал в спектрограмму с помощью быстрого преобразования Фурье (БПФ), где каждый пиксель представляет собой магнитуду (амплитуду) определенной частоты в определенный момент времени. Обработка происходит над этой спектрограммой, после чего полученная маска применяется к исходной спектрограмме для извлечения целевого источника, а затем выполняется обратное преобразование Фурье для получения результирующей аудиодорожки.

Архитектура модели Open-Unmix описана в статье [6] и приведена на рисунке 1.2.

Общая идея модели Open-Unmix заключается в преобразовании исходного файла смеси (микса) музыкальных инструментов в формате спектрограммы (на схеме этот блок назван "mix spectrograms") в набор спектрограмм отдельных музыкальных инструментов из этого микса (на схеме это – "target spectrograms").

Модель Open-Unmix состоит из следующих компонентов:

- 1) Подготовка входных данных ("Cropping 16 kHz" "Input Scaler") – на этом этапе происходит дробление исходного аудио (разделение по 16КГц) и нормализация входных спектрограмм для улучшения качества работы модели.
- 2) Энкодер (кодировщик) – это отдельная модель внутри Open-Unmix, которая занимается сжатием входного аудиопотока в компактный набор при-




Рисунок 1.2 – Архитектура модели Open-Unmix [7]

знаков. В свою очередь модель энкодера состоит из следующих блоков:

- **fc1 (Fully Connected)** – слой нейросети, который начинает анализировать данные.
- **bn1 (Batch Normalization)** – это слой нейронной сети, который реализует алгоритм нормализации. Слой bn1 обозначает первый слой пакетной нормализации (Batch Normalization layer) в архитектуре модели. Это обучаемый блок, который стабилизирует распределение активаций внутри **мини-батча**, ускоряет сходимость обучения и часто выступает как мягкий регуляризатор. В схеме он расположен между полносвязным слоем fc1 и нелинейной функцией активации tanh.
- **tanh** функция гиперболического тангенса – нелинейная функция активации, которая решает, какие сигналы пропустить дальше, а какие остановить. Формула функции гиперболического тангенса имеет вид:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (1.1)$$

не хватает «где»

- 3) Центральный модуль модели – блок, реализованный на основе двунаправленной долговременной краткосрочной памяти (Bidirectional Long Short-Term Memory, BLSTM), выделенный на схеме фиолетовой рамкой. Данный компонент отвечает за моделирование нестационарных временных зависимостей музыкального сигнала. Блок BLSTM реализован в виде каскада из трёх последовательно соединённых рекуррентных слоёв (обозначение ×3 на схеме). Многослойная архитектура обеспечивает иерархическое извлечение признаков: нижние слои кодируют низкоуровневые вре-

менные паттерны (огибающие, **транзиенты**), тогда как верхние слои **агрегируют** их в высокоуровневые **семантические** представления музыкальной структуры (мотивы, аккордовые прогрессии, тембральные характеристики). Для стабилизации обучения глубокой рекуррентной сети и компенсации проблемы затухания градиентов применяется механизм остаточного соединения (Skip Connection). Фиолетовая стрелка на схеме обозначает суммирование входного тензора с выходом блока BLSTM:

$$y = x + \mathcal{F}_{\text{BLSTM}}(x), \quad (1.2)$$

где

- x — входное представление,
- $\mathcal{F}_{\text{BLSTM}}(\cdot)$ — преобразование, выполняемое стеком BLSTM-слоёв.

Данный приём обеспечивает прямой градиентный поток на всех этапах обратного распространения, сохраняет низкоуровневую спектральную информацию и ускоряет сходимость оптимизатора без риска деградации представлений при увеличении глубины сети.

- 4) Декодер – модуль, отвечающий за восстановление представлений, сжатых в энкодере. После извлечения временных зависимостей блоком BLSTM следует модуль декодирования, целью которого является восстановление размерности и структуры тензора, необходимого для последующего формирования маски. В данной конфигурации используются следующие элементы:

- Слои fc2 и fc3 (Fully Connected): Выполняют трансформацию скрытого вектора в пространство признаков, совместимое с размерностью входной спектрограммы.

- Слои bn2 и bn3 (Batch Normalization) обеспечивают нормализацию активаций на промежуточных этапах декодирования, предотвращая смещение распределения признаков (covariate shift) перед нелинейностями.

- Функция активации ReLU (Rectified Linear Unit). В отличие от сигмоидальных функций, используемых ранее, на этапе декодирования применяется функция:

- 5) Мультипликативное маскирование (Multiplicative Skip-Connection) – механизм определения и применения маски для получения итогового результата разделенных источников. Прямая генерация спектрограммы «с нуля» часто приводит к артефактам и фазовым искажениям. Вместо такого подхода модель Open-Unmix вычисляет массивную маску (full-band

mask) $\hat{M}$, которая определяет коэффициент присутствия целевого источника для каждого **бина** спектрограммы. Процесс разделения описывается формулой поэлементного умножения (Hadamard product):

$$\hat{\mathbf{S}} = \mathbf{X} \odot \hat{\mathbf{M}}, \quad (1.3)$$

где

- $\mathbf{X} \in R^{T \times F}$ — исходная входная спектрограмма смеси (суммарное представление всех инструментов),
- $\hat{\mathbf{M}} \in R^{T \times F}$ — предсказанная нейросетью маска (выход модуля декодирования после функции активации ReLU, обеспечивающей неотрицательность значений),
- $\hat{\mathbf{S}}$ — результирующая спектрограмма целевого источника (например, вокала или гитары).

Таким образом, архитектура Open-Unmix реализует сквозной конвейер частотно-временного разделения источников, в котором входная спектрограмма смеси последовательно проходит через блок извлечения признаков, двунаправленную рекуррентную сеть для моделирования временных зависимостей и декодер, формирующий оценку маски присутствия целевого сигнала. Финальное выделение изолированной дорожки осуществляется путём поэлементного умножения предсказанной маски на исходную спектрограмму, что обеспечивает восстановление целевого источника с сохранением фазовой информации и минимизацией артефактов, характерных для генеративных моделей.

Модель Open-Unmix имеет как преимущества, так и недостатки среди моделей, решающих эту же задачу разделения источников. Среди преимуществ можно отметить:

- 1) Высокая воспроизводимость и открытость. Авторы модели Open-Unmix называют её эталонной реализацией [6] для задач разделения источников. Код, предобученные веса и документация находятся в открытом доступе, что обеспечивает полную воспроизводимость результатов и упрощает интеграцию в исследовательские и прикладные проекты.
- 2) Эффективное моделирование временного контекста. Применение двунаправленной LSTM-сети (BLSTM) позволяет модели учитывать как предшествующий, так и последующий контекст относительно текущего фрейма [9]. Это преимущество важно для разделения гармонически насыщенных сигналов, где выделение источника часто требует анализа музыкальной фразы целиком.
- 3) Баланс качества и вычислительной сложности. Архитектура демонстри-

рует конкурентоспособное качество на **бенчмарках** (например, MUSDB18) при умеренных требованиях к ресурсам по сравнению с более тяжёлыми генеративными моделями (Diffusion, GAN). Этот принцип делает модель пригодной для **офлайн-обработки** и моделирования при отсутствии больших вычислительных мощностей.

- 4) Модульность и расширяемость. Чёткое разделение на блоки кодирования, рекуррентной обработки и декодирования позволяет адаптировать архитектуру под специфические задачи: замену BLSTM на Transformer, добавление многозадачного обучения или расширение на новые классы источников.

Но модель Open-Unmix также имеет следующие ограничения:

- 1) Вычислительная сложность рекуррентных слоёв. Последовательная природа LSTM-ячеек ограничивает возможности параллелизации при обучении и **инференсе**. Обработка длинных аудиопоследовательностей требует значительного времени и памяти, что затрудняет применение модели в системах реального времени с низкой задержкой.
- 2) Допущение о независимости источников. Подход на основе идеальных масок (Ideal Ratio Mask) предполагает, что источники в смеси аддитивны и слабо коррелированы. В случаях сильного спектрального перекрытия (например, вокал и соло-гитара в одном частотном диапазоне) качество разделения может снижаться из-за компромиссов при оценке маски.
- 3) Отсутствие явного моделирования фазы. Поскольку маска применяется только к амплитуде спектрограммы, фазовая информация копируется из смеси без коррекции. Это может приводить к остаточным артефактам («фазовый шум») в областях, где целевой источник и интерференция имеют близкие частоты, но противоположные фазы.

Архитектура Open-Unmix представляет собой сбалансированное решение для задачи разделения музыкальных источников, сочетающее интерпретируемость, воспроизводимость и конкурентоспособное качество. Основные ограничения модели связаны с вычислительной сложностью рекуррентных блоков и допущениями, лежащими в основе подхода маскирования. Перспективными направлениями развития модели являются замена BLSTM на архитектуры с глобальным вниманием (Transformer), совместное моделирование амплитуды и фазы, а также адаптация под **инференс** с низкой задержкой для применения в интерактивных системах.

Spleeter Spleeter — это система разделения музыкальных источников, разработанная компанией Deezer [10]. Модель основана на архитектуре U-Net [2],

работающей в частотной области, и обучена на синтетически сгенерированном датасете из 25 тысяч композиций. В отличие от рекуррентных подходов (Open-Unmix), Spleeter использует полностью сверточную архитектуру типа U-Net, что обеспечивает высокую скорость обработки за счёт параллелизации вычислений.

Spleeter поддерживает разделение на 2, 4 или 5 источников (vocals, drums, bass, piano, other), что делает её одной из первых промышленных систем, ориентированных на широкое применение.

Архитектура модели Spleeter в соответствии с документацией [11] включает следующие компоненты:

- 1) Входное представление (Input Representation). Входной аудиосигнал $x(t)$ преобразуется в комплексную спектрограмму с помощью кратковременного преобразования Фурье (STFT) с окном 4096 и шагом 1024.
- 2) Энкодер (Encoder). Энкодер извлекает иерархические признаки из входной спектрограммы с помощью последовательности сверточных блоков. Каждый блок включает:
 - Свертку 3×3 с шагом 2 (downsampling);
 - Пакетную нормализацию (Batch Normalization);
 - Функцию активации ReLU.
- 3) Блок сжатия (bottleneck – «горлышко бутылки», узкое место) – это центральный блок слоёв, в котором формируется наиболее сжатое представление признаков. Такое сжатие позволяет модели выделять наиболее существенные абстрактные характеристики музыкального сигнала, отфильтровывая шум и несущественные детали.
- 4) Декодер с пропущенными связями. Декодер восстанавливает пространственное разрешение признаков с помощью транспонированных сверток (Transposed Convolution).
- 5) Выходной слой и маскирование. Выход модели представляет собой маску, применяемую к исходной спектрограмме для извлечения целевого источника. Обратное преобразование Фурье (iSTFT) используется для восстановления временного сигнала.

Модель Spleeter имеет следующие преимущества:

- 1) Высокая скорость выполнения запроса. Благодаря полностью сверточной архитектуре без рекуррентных связей, все вычисления могут быть распараллелены на GPU. Обработка трека происходит в 5–10 раз быстрее, чем в реальном времени, что делает модель пригодной для потоковых сервисов.

- 2) Эффективное сохранение деталей. Архитектура модели Spleeter, основанная на модели U-Net с механизмом skip-connections позволяет восстанавливать высокочастотные компоненты, которые часто теряются в архитектурах с сильным сжатием, обеспечивая «прозрачное» звучание.
- 3) Устойчивость к переобучению. Использование пакетной нормализации и умеренной глубины сети (по сравнению с Transformer-моделями) снижает риск переобучения на небольших датасетах.

Также существуют значимые ограничения в работе модели Spleeter:

- 1) Частотные артефакты. Работа исключительно в магнитудной области с сохранением фазы из смеси приводит к артефактам в областях сильного спектрального перекрытия источников.
- 2) Малая гибкость архитектуры. Фиксированная структура U-Net сложнее адаптируется под новые классы источников или многозадачное обучение по сравнению с модульными подходами (Open-Unmix, Demucs).

1.4 Анализ методов дообучения предобученных моделей разделения источников

Существуют задачи, в рамках которых средств существующих предобученных нейронных сетей недостаточно и возникает потребность провести над выбранной нейронной сетью ряд действий, позволяющих «научить» её тому контексту, которому она не была «обучена» ранее, в процессе основного обучения, но которого не хватает для решения специфичной исследовательской задачи. При этом чаще всего такое обучение требуется провести без утраты тех «знаний», которым была обучена модель первоначально, так как повторное переобучение модели с нуля – дорогостоящий процесс, требующий больших вычислительных мощностей, больших наборов данных, настройки всех параметров и т.д.

В таких случаях современные исследователи прибегают к подходу дообучения модели, в рамках которого модель не требуется переобучать заново, но необходимо провести её «тонкую настройку» (fine-Tuning) [15] [13] – то есть на уровне механики модели провести некоторые действия, чтобы научить нейронную сеть новым концептам с максимальным сохранением предыдущего накопленного опыта.

В случае задачи разделения источников в аудиосигнале обучение предобученной архитектуры модели с открытым исходным кодом на целевом датасете позволяет адаптировать модель к специфическим классам источников, о которых модель не «знала» и которые не умела извлекать до этого, без необхо-

димости обучения «с нуля».

Метод «тонкой настройки» в настоящее время применяется повсеместно на различных генеративных моделях ИСТОЧНИКИ НУЖНЫ. В зависимости от вычислительных ограничений и объёма данных для решения задачи дообучения применяется одна из трех основных стратегий: полная тонкая настройка, частичная настройка выходного блока и адаптация низкого ранга [14].

1.4.1 Полное дообучение

Полное дообучение подразумевает обновление всех весов предобученной модели на новом, целевом наборе данных.

Все параметры предобученной модели размораживаются, и оптимизатор обновляет веса всех слоёв на новом датасете. Обучение проводится с пониженным коэффициентом обучения (learning rate), чтобы не разрушить уже усвоенные общие признаки звука, но позволить сети адаптироваться к новому распределению данных.

В контексте моделей разделения источников звука это означает повторное обучение всей сети на собственном датасете с дорожками тех инструментов, которые модель не умеет извлекать, с возможной корректировкой функции потерь и архитектурных деталей.

Основное преимущество данного подхода — максимальная гибкость адаптации модели к специфике задачи, в том числе к особенностям частотного диапазона и перекрытию гармоник между инструментами. Также к преимуществам можно отнести:

- 1) Простота реализации: не требует модификации архитектуры, чаще всего достаточно внести небольшое количество изменений.
- 2) При достаточном объёме данных демонстрирует наивысшее качество разделения.

В то же время, полное дообучение требует значительных вычислительных ресурсов, длительного времени сходимости, высокого объёма целевого датасета и аккуратного подбора гиперпараметров, поскольку существует риск переобучения и потери уже выученных обобщённых признаков.

1.4.2 Методы «параметрического» дообучения (адаптация части параметров)

Существует класс методов, которые отталкиваясь от концепции метода полного дообучения, дообучают не полностью всю модель, а только часть её весов: замораживают основную массу весов предобученной модели и обучают лишь малую добавочную часть параметров (обычно $< 5\%$ от общего числа). Та-

кие методы называют ”частичным дообучением”или ”параметрически эффективная адаптация”**НУЖНЫ ИСТОЧНИКИ**.

Суть метода заключается в том, что все слои Энкодера и рекуррентного/сверточного блока, размораживается только выходной слой (декодер или классификационная «голова») [15]. Модель использует предобученные признаки общего звукового представления, а перестраивается только механизм маппинга признаков в целевые маски источников [15].

Преимущества такого подхода перед методом полного дообучения заключаются в следующем:

- 1) Минимальные требования к памяти и времени обучения [15].
- 2) Высокая стабильность: модель не теряет общие акустические паттерны [15] [12].
- 3) Простота отладки и быстрая проверка гипотез о составе датасета [15].

Но несмотря на преимущества, у метода есть ограничения:

- 1) Низкая гибкость: если спектры пианино и гитары существенно отличаются от распределения, на котором обучался энкодер, качество разделения будет ограничено «потолком» замороженных признаков [12].
- 2) Не подходит для задач с сильным доменным сдвигом (например, переход от студийных записей к live-концертам или **лоу-фай семплам**) [12].

1.4.3 Адаптация низкого ранга (LoRA, Low Rank Adaptation)

Метод LoRA (англ. Low Rank Adaptation – дословно переводится как «адаптация на основе низкого ранга») был разработан для больших языковых генеративных моделей (LLM) [16], но нашёл применение в большом пласте работ по дообучению моделей в машинном обучении **ТОЖЕ ИСТОЧНИКИ НУЖНЫ** напр SD.

Основное отличие LoRA от методов полного дообучения и частичного дообучения заключается в том, что здесь адаптируется некоторое количество параметров, результатом метода LoRA являются те веса, которые были преобразованы. Низкоранговые методы дообучения основаны на идее замены части весов матриц на низкоранговые приращения, которые обучаемы, а исходные веса при этом остаются неизменными. Подход LoRA схематично представлен на рисунке 1.3.

Суть подхода LoRA представлена в названии метода: исследователи при создании этого метода проверяли гипотезу, которая заключалась в том, что внутренняя размерность (ранг) матрицы весов $\Delta W = W_{fine_tuning} - W_0$ (где W_{fine_tuning} – веса модели после дообучения, W_0 – веса исходной модели) в больших моделях обладает низким рангом (intrinsic rank), несмотря на то, что исходная

матрица весов W_0 имеет полный ранг. Это явление объясняется избыточной параметризацией (overparameterization) современных нейросетей [17]: число обучаемых параметров значительно превышает минимально необходимое для решения задачи, что позволяет оптимизатору концентрировать полезные градиенты в низкоранговом подпространстве без потери обобщающей способности (то есть «предыдущих знаний»).




Рисунок 1.3 – Структура подхода LoRa. Собственный материал

Такое предположение позволяет декомпозировать изменение весов в виде произведения двух матриц более низкого ранга, чем матрица весов (а не оптимизировать саму матрицу весов изменяемого слоя):

$$\Delta W = BA, \quad (1.4)$$

где

- $A \in R^{r \times k}$ – матрица размерности $r \times k$,
- $B \in R^{d \times r}$ – матрица размерности $d \times r$,
- $r \ll \min(d, k)$ – ранг матрицы W , должен быть как можно меньше.

В процессе дообучения методом LoRA корректируются только матрицы A и B (считаются их градиенты и обновляются), что позволяет существенно снизить объём обучаемых параметров и требования к памяти GPU. Модель обучается лишь в низкоранговом подпространстве, которое описывается этими низ-

коранговыми матрицами, причём веса модели W_0 замораживаются и не преобразуются. Для получения итогового результата матрицы складываются:

$$y = W_0x + \Delta Wx = W_0x + BAx, \quad (1.5)$$

где

- A инициализируется Гауссовским распределением $A = N(0, \sigma^2)$,
- B инициализируется 0,
- W_0 – исходная матрица обучаемой модели.

Таким образом, LoRA заменяет полное обновление весов на обучение только компактных адаптеров, что сокращает количество обновляемых параметров на 70–91 % [16], снижает потребление видеопамати и минимизирует риск катастрофического забывания исходных знаний модели, который часто сопутствует методам полного дообучения. В задаче выделения аудио источников, метод LoRA может применяться к отдельным слоям или компонентам модели (например, слоям свёртки или частотно-временным модулям), что позволяет выполнять адаптацию параметров без изменения архитектуры исходной сети.

Среди преимуществ метода разработчики LoRA приводят следующие [16]:

- 1) Адаптеры LoRA небольшого размера, в связи с чем требования к размеру ресурсов для их расположения достаточно снижены.
- 2) Сниженные требования к видеопамати (VRAM). Метод не предусматривает выполнение тяжёлых операций расчёта градиентов для большинства параметров модели, следовательно, подход менее ресурсозатратен и поддерживает минимальные требования к железу. Это позволяет проводить эксперименты с крупными архитектурами в средах с ограниченными ресурсами (например, Google Colab в бесплатной версии).
- 3) Модульность и возможность переиспользования. Веса адаптеров A и B хранятся отдельно от базовой модели и могут быть дополнительно загружены или заменены без внесения изменений в архитектуру исходной модели. В рамках задачи извлечения источников, это позволяет поддерживать библиотеку адаптеров для различных инструментов (пианино, гитара, вокал) и комбинировать их при запуске модели.
- 4) Отсутствие катастрофического забывания. Заморозка исходных весов W_0 сохраняет знания, усвоенные моделью на этапе предобучения.

Также можно отметить следующие ограничения метода:

- 1) Необходимость подбора ранга r . Значение ранга r является гиперпараметром, требующим эмпирической настройки. Слишком малое r может ограничивать способность адаптации, а чрезмерно большое r нивелирует

преимущества метода по экономии параметров и памяти при его использовании.

- 2) Ограничения при больших различиях в данных. Гипотеза о низком ранге обновлений ΔW может нарушаться при адаптации к задачам, радикально отличающимся от распределения данных предобучения (например, переход от студийных записей к полевым записям с низким соотношением сигнал/шум). В таких случаях полное дообучение может демонстрировать более высокую точность и быть более эффективным решением.

1.5 Функции потерь

1.6 Метрики оценки качества (SDR, SIR, SAR)

В основных исследованиях, направленных на изучение дообучения моделей разделения источников, полученные результаты оцениваются при помощи метрик, которые являются стандартами в части оценки [18].

Для объективной оценки качества разделения источников для сравнения соответствующих методов применяются метрики, основанные на сравнении предсказанных сигналов $\hat{s}_k$ с эталонными (ground truth) источниками s_k . Данная методология предполагает разложение общей ошибки на две независимые составляющие: влияние компонентов посторонних источников в исходном аудиосигнале (интерференция) и искажения, внесённые алгоритмом разделения (артефакты). Такой подход позволяет независимо оценивать два аспекта качества: эффективность подавления посторонних сигналов (инструментов, шумов) и чистоту извлечения целевого источника (насколько естественно звучит исходный источник).

В данной работе используются метрики семейства BSS Eval (Blind Source Separation Evaluation) [18] и их модификация SI-SDR. Набор оценочных метрик формировался в соответствии с методологией оригинальных исследований сравниваемых архитектур: для Open-Unmix [6] основным показателем выступает SDR, для Demucs [1] применяются SDR, SIR и SAR, а для Spleeter [10] используется полный набор метрик BSS Eval (SDR, SIR, SAR, ISR). Такой подход обеспечивает методологическую согласованность и корректность сравнительного анализа в рамках принятых в предметной области стандартов.

1.6.1 Декомпозиция сигнала по методу BSS Eval

Согласно методологии декомпозиции сигнала [18], оценённый источник $\hat{s}$ представляется в виде суммы ортогональных компонент:

$$\hat{s} = s_{\text{target}} + e_{\text{interf}} + e_{\text{noise}} + e_{\text{artif}}, \quad (1.6)$$

где

- $\hat{s}$ — оцениваемый сигнал, полученный в результате работы модели,
- s_{target} — проекция на исходный аудиоисточник,
- e_{interf} — компонента интерференции (посторонние источники),
- e_{noise} — компонента шума (фоновый шум, шум оборудования, не связанный с целевыми источниками),
- e_{artif} — компонента артефактов (искажения алгоритма),

В условиях отсутствия явного шума в датасетах компонента e_{noise} часто пренебрегается и объединяется с компонентой e_{artif} , так как оба слагаемых представляют собой «нежелательную» часть сигнала, не относящуюся ни к целевому источнику, ни к интерференции. При вычислении метрик SDR, SIR, SAR в популярной библиотеке `mir_eval`, шум e_{noise} часто не выделяется отдельно, если не задан эталонный сигнал шума.

В рамках данного исследования, использующего датасет без явного фонового шума (например, MUSDB18), компонента e_{noise} считается пренебрежимо малой и объединяется с компонентой артефактов. Таким образом, для расчёта метрик применяется упрощённая декомпозиция: $\hat{s} \approx s_{\text{target}} + e_{\text{interf}} + e_{\text{artif}}$.

На основе этой декомпозиции вычисляются три основные метрики (в децибелах, дБ), каждая из которых характеризует определённый аспект качества разделения: SDR отражает общее отношение полезного сигнала к сумме всех ошибок, SIR измеряет эффективность подавления интерферирующих источников, а SAR оценивает уровень артефактов, внесённых алгоритмом обработки.

Signal-to-Distortion Ratio (SDR) — Отношение сигнал/искажения SDR (Signal-to-Distortion Ratio, отношение сигнала к искажению) является интегральной метрикой, оценивающей общее качество разделения с учётом всех типов ошибок (интерференция + артефакты).

Чем выше значение, тем лучше. Значение 0 дБ означает, что мощность сигнала равна мощности ошибок. Увеличение на 10 дБ соответствует десятикратному улучшению отношения сигнал/шум.

Signal-to-Interference Ratio (SIR) — Отношение сигнал/интерференция SIR измеряет способность модели подавлять другие источники в смеси (например, насколько чисто удалён вокал из инструментальной дорожки).

Высокий SIR указывает на эффективное разделение источников, но не гарантирует отсутствие артефактов (например, «музыкального шума»).

Signal-to-Artifacts Ratio (SAR) — Отношение сигнал/артефакты SAR оценивает «чистоту» извлечённого источника, игнорируя остатки других инструментов. Метрика чувствительна к искажениям, вносимым самим алгорит-

мом (фазовые искажения, пре-эхо, свист).

Критически важна для субъективного восприятия качества. Низкий SAR часто коррелирует с наличием слышимых артефактов, даже если общий SDR высок.

1.6.2 Масштабно-инвариантная метрика (SI-SDR)

Классические метрики чувствительны к глобальному масштабу (громкости) сигнала. Метрика Scale-Invariant SDR (SI-SDR) устраняет эту зависимость, что делает её более устойчивой при сравнении методов, которые могут изменять амплитуду выхода.

Пусть s — эталонный сигнал, $\hat{s}$ — оцениваемый сигнал. Определим проекцию $\hat{s}$ на направление s :

Формула метрики:

2 Разработка архитектуры программного обеспечения

2.0.1 Выбор базовой модели среди существующих для извлечения конкретных инструментов

В ходе сравнительного анализа существующих подходов к задаче разделения музыкальных источников в качестве базовой модели была выбрана архитектура Open-Unmix. Данное решение обусловлено совокупностью технических, вычислительных и методологических факторов

2.1 Выбор способа дообучения

В ходе сравнительного анализа существующих подходов к задаче разделения музыкальных источников в качестве базовой модели была выбрана архитектура Open-Unmix. Данное решение обусловлено совокупностью технических, вычислительных и методологических факторов, напрямую соответствующих целям настоящего исследования.

Во-первых, Open-Unmix позиционируется авторами как reference implementation (эталонная реализация) [6], что обеспечивает высокую прозрачность кода, модульность архитектуры и стабильность процесса дообучения. В отличие от трансформерных моделей (например, Demucs v4), требующих значительных объёмов видеопамяти и длительного времени сходимости [1], Open-Unmix использует двунаправленные LSTM-блоки с пакетной нормализацией. Такая конфигурация существенно снижает вычислительную нагрузку и позволяет проводить эксперименты в среде Google Colab без риска исчерпания квот GPU или нестабильности обучения на бесплатных тарифах и мощностях.

Во-вторых, частотно-временной подход с мультипликативным маскированием ($\hat{S} = X \odot \hat{M}$) демонстрирует высокую эффективность при работе с гармоническими инструментами, такими как фортепиано и акустическая/электрогитара [12]. Спектральные огибающие данных инструментов обладают выраженной структурой в STFT-представлении, что позволяет модели обучаться устойчивым маскам присутствия даже при частичном частотном перекрытии. Архитектура поддерживает transfer learning: предобученные веса для стандартных классов (вокал, бас, ударные) могут быть адаптированы под целевые инструменты без полного перезапуска оптимизации, что критически важно при ограниченном объёме размеченных данных [6].

В-третьих, в сравнении с альтернативными решениями, Open-Unmix обладает архитектурной гибкостью, необходимой для кастомизации под задачу. Модель Spleeter использует softmax-нормализацию масок по каналам источников, что жёстко фиксирует их количество и затрудняет добавление новых клас-

сов без перестройки выходного слоя. Demucs, работая в гибридном временно-частотном домене, генерирует источники напрямую, что усложняет интерпретацию промежуточных представлений и требует значительных ресурсов для тонкой настройки [1]. Open-Unmix же предсказывает независимые маски для каждого инструмента, сохраняя аддитивность смеси и позволяя масштабировать выходной слой под произвольное число целевых классов [6].

Таким образом, выбор Open-Unmix представляет собой сбалансированное решение, сочетающее воспроизводимость, вычислительную доступность и архитектурную гибкость. Модель полностью соответствует требованиям исследования по извлечению партий фортепиано и гитары, обеспечивая возможность дообучения в условиях ограниченных вычислительных ресурсов при сохранении академической строгости и сопоставимости результатов с современными бенчмарками.

- Архитектура Hybrid Transformer Demucs - Анализ ошибок базовой модели на тестовом наборе - Предложенные модификации: * Гитаро-специфичные аугментации * Дообучение на проблемных примерах * Фокусировка на критичных частотных диапазонах - Методика оценки результатов - спецификация скриптов?

архитектура программного решения, алгоритм выбора модели и результатах экспериментов

3 Разработка алгоритмов и программного обеспечения

- скрипты - Описание тестового набора данных - Результаты базовой модели Demucs - Результаты адаптированной модели - Сравнительный анализ метрик - Субъективная оценка качества

ЗАКЛЮЧЕНИЕ

- Основные результаты работы - Практическая значимость - Направления
будущих исследований

СПИСОК ЛИТЕРАТУРЫ

1. *A. Défossez, N. Usunier, L. Bottou, u F. Bach* Hybrid Transformers for Music Source Separation // 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2023. P. 1–5.
2. *H. Huang u dp.*, «UNet 3+: A Full-Scale Connected UNet for Medical Image Segmentation», ICASSP, IEEE Int. Conf. Acoust. Speech Signal Process. - Proc., т. 2020-May, вып. ii, сс. 1055–1059, 2020, doi: 10.1109/ICASSP40776.2020.9053405.
3. *A. Belouchrani, M. G. Amin, N. Thirion-Moreau, u Y. D. Zhang* «Source separation and localization using time-frequency distributions: An overview», IEEE Signal Process. Mag., т. 30, вып. 6, сс. 97–107, 2013, doi: 10.1109/MSP.2013.2265315.
4. *N. I. Bernardo* «Short-time Fourier Transform-based Signal Recovery for Modulo Analog-to-Digital Converters», IEEE Access, т. 14, вып. December 2025, сс. 7308–7324, 2026, doi: 10.1109/ACCESS.2026.3653404
5. *S. Rouard, F. Massa, u A. Defossez*, «Hybrid Transformers for Music Source Separation», ICASSP, IEEE International Conference Acoustics. Speech Signal Process. - Proc., т. 2023-June, сс. 2–6, 2023, doi: 10.1109/ICASSP49357.2023.10096956.
6. *F.R. Stöter, S. Uhlich, A. Liutkus, u Y. Mitsufuji* , Open-Unmix: A Reference Implementation for Music Source Separation // 2019 IEEE Workshop on Applications of Signal Processing to Audio and Acoustics (WASPAA). 2019. P. 1–5.
7. *Uhlich S. et al.* Open-Unmix: A Deep Neural Network Reference Implementation for Music Source Separation – GitHub. 2019. – URL: <https://github.com/sigsep/open-unmix-pytorch>
8. *Schuster M., Paliwal K.* Bidirectional recurrent neural networks // IEEE Transactions on Signal Processing. 1997. Т. 45, № 11. С. 2673–2681.
9. *L. Huang, G. Cheng, P. Zhang, Y. Yang, S. Xu, u J. Sun* «Utterance-level Permutation Invariant Training with Latency-controlled BLSTM for Single-channel Multi-talker Speech Separation».

10. *R. Hennequin, A. Khlif, u F. Voituret* Spleeter: A Fast and Efficient Music Source Separation Tool with Pre-trained Models // Journal of Open Source Software. 2020. Vol. 5, No. 50. P. 2154.
11. «Core Architecture | deezer/spleeter | DeepWiki». [Онлайн]. Доступно на: <https://deepwiki.com/deezer/spleeter/2-core-architecture>
12. *Wang D., Chen J.* Supervised Speech Separation Based on Deep Learning: An Overview // IEEE/ACM Transactions on Audio, Speech, and Language Processing. 2018. Vol. 26, No. 10. P. 1702–1726.
13. Y. Zhang, D. Zhang, T. Wang, D. Rakhimova, K. Wang and H. Huang, "Domain Partitioning Meets Parameter-Efficient Fine-Tuning: A Novel Method for Improved Language-Queried Audio Source Separation," ICASSP 2026 - 2026 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Barcelona, Spain, 2026, pp. 15637-15641
14. Xu L. et al. Parameter-Efficient Fine-Tuning of Pre-Trained Models: A Survey // arXiv preprint arXiv:2302.08656. 2023.
15. Goodfellow I., Bengio Y., Courville A. Deep Learning. Cambridge, MA: MIT Press, 2016. 800 p.
16. Hu E. J. et al. LoRA: Low-Rank Adaptation of Large Language Models // arXiv preprint arXiv:2106.09685. 2021.
17. Zeng R., Lee V. The Expressive Power of Low-Rank Adaptation // The Twelfth International Conference on Learning Representations (ICLR). 2024.
18. Vincent E., Gribonval R., Févotte C. Performance measurement in blind audio source separation // IEEE Transactions on Audio, Speech, and Language Processing. 2006. Vol. 14, No. 4. P. 1462–1469. DOI: 10.1109/TSA.2005.858005.
19. Le Roux J. et al. SDR—Half-Baked or Well Done? // 2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2019. P. 626–630. DOI: 10.1109/ICASSP.2019.8683366.

СЛУЖЕБНАЯ ИНФОРМАЦИЯ

Список иллюстраций

1.1	Упрощенный процесс разделения источников из аудиозаписи. Источники	7
1.2	Архитектура модели Open-Unmix [7]	12
1.3	Структура подхода LoRa. Собственный материал	20

**Список картинок нужен только для прохождения нормоконтроля.
В диплом он не вшивается!**

СЛУЖЕБНАЯ ИНФОРМАЦИЯ

Список таблиц

**Список таблиц нужен только для прохождения нормоконтроля.
В диплом он не вшивается!**

СЛУЖЕБНАЯ ИНФОРМАЦИЯ

Листинги

**Список листингов нужен только для прохождения нормоконтроля.
В диплом он не вшивается!**