

ВВЕДЕНИЕ

Задача автоматического разделения музыкальных источников является одной из ключевых в области цифровой обработки сигналов и машинного обучения. Технологии выделения отдельных инструментов из полифонических записей находят применение в музыкальном продюсировании и реставрации архивных аудиоматериалов [1], в системах автоматического анализа музыкальных композиций и интеллектуальной обработки аудиосигналов [2, 3].

Современные подходы к разделению источников опираются на глубокие нейронные сети, работающие в частотной или временной области. Значительный прогресс достигнут в создании универсальных моделей, обученных на крупных размеченных наборах данных и демонстрирующих высокое качество на стандартных наборах классов [1].

Несмотря на значительный прогресс в разработке нейросетевых архитектур, способных выделять стандартные классы источников (вокал, ударные, бас), качественное разделение гармонических инструментов со значительным частотным перекрытием, таких как фортепиано и гитара, остаётся сложной и недостаточно изученной проблемой. Практическая потребность в точном извлечении таких инструментов обусловлена как задачами профессионального сведения, так и развитием автоматизированных систем анализа музыкального контента, что определяет высокую актуальность данного исследования. Однако существующие решения обладают рядом ограничений. Во-первых, модели, рассчитанные на широкий спектр инструментов, часто формируют неточные маски при выделении источников со схожими спектральными огибающими, что приводит к появлению артефактов фильтрации и взаимному «протеканию» сигналов [4]. Во-вторых, адаптация таких архитектур под новые, специфичные классы источников требует либо полного переобучения, что недоступно при ограниченных вычислительных ресурсах, либо применения методов дообучения, разработанных преимущественно для языковых моделей и компьютерного зрения.

В настоящее время в научной литературе существуют ограниченное количество работ, в которых реализуется применение эффективного дообучения именно для нейросетевых моделей разделения аудиоисточников: к примеру, в рамках статьи [5] исследуется возможность и эффективность применения промтов к извлечению источников из аудиопотока. В работе [6]

впервые параметрически эффективный метод низкоранговой адаптации [7] был применён к модели извлечения источников AudioSep для изучения эффективного дообучения при небольшом количестве эпох и показал, что качество выделения значительно улучшилось после проведённого дообучения.

Успешное применение метода низкоранговой адаптации к задачам обработки речевых сигналов было произведено в рамках статьи [8]. Это позволяет также предположить эффективность метода и для задач разделения музыкальных источников, где также требуется адаптация общих признаков к специфичным классам.

Выявленная проблема отсутствия научной базы в области применения методов параметрически-эффективного дообучения к моделям извлечения аудиоисточников говорит о необходимости проведения исследования по изучению эффективности и качества моделей этого типа после применения методов полного дообучения и параметрически-эффективной адаптации.

Цель работы: повышение качества и эффективности извлечения звука музыкальных инструментов из звукового потока посредством применения методов дообучения специализированных моделей искусственного интеллекта, используемых для разделения аудиоисточников.

В соответствии с целью были выделены следующие задачи:

- Провести анализ архитектур моделей извлечения аудиоисточников и определить ограничения в их работе.
- Сформировать собственный набор данных для проведения дообучения базовых моделей для решения выявленных ограничений.
- Спроектировать и реализовать алгоритм дообучения базовых моделей разделения аудиоисточников.
- Провести эксперименты по запуску дообученных модели и оценить полученные результаты.

Объект исследования: нейросетевые архитектуры разделения музыкальных источников, работающие в частотной и временной области.

Предмет исследования: методы полного дообучения и параметрически эффективной адаптации моделей для выделения музыкальных инструментов.

Настоящая работа состоит из введения, трёх глав, заключения, списка использованных источников и приложений. В первой главе представлен теоретический обзор архитектур разделения источников, методов адаптации нейронных сетей и метрик оценки качества. Во второй главе описаны

проектирование экспериментального конвейера, формирование набора данных и программная реализация алгоритмов дообучения. Третья глава содержит результаты проведённых экспериментов, сравнительный анализ моделей и выводы по полученным данным.

1 АНАЛИЗ СОСТОЯНИЯ ИССЛЕДОВАНИЯ В ОБЛАСТИ ИЗВЛЕЧЕНИЯ ИСТОЧНИКОВ ЗВУКА

Выделение аудио-источников (Audio Source Separation) — процесс извлечения заранее определённого набора источников звука из смешанного аудиосигнала. Цель такой задачи — выделить конкретные источники, например вокал, инструменты или фоновый шум, из сложной аудиозаписи (рисунок 1.1).




Рисунок 1.1 – Упрощенный процесс разделения источников из аудиозаписи.

Авторский материал

Для разделения источников используются алгоритмы обработки сигналов, которые используют различные техники: спектральный анализ, анализ во временной и частотной областях, машинное обучение.

Итогом выполнения задачи декомпозиции смешанного аудиосигнала являются выходные данные в виде компонент, представляющих собой изолированные аудиодорожки исходного источника (например, партию гитары, барабанов или вокала). Такая аудиодорожка является единицей музыкального аудиопотока в задаче выделения источников. Когда происходит запись в студии звукозаписи, например, музыкального трека, то происходит запись отдельных музыкальных инструментов и вокала и образуется финальная композиция. И цель задачи извлечения сигналов, в том, чтобы воссоздать эти индивидуальные дорожки из смешанного сигнала-музыкальной дорожки.

Притом, такая задача подразумевает получение из одного аудиотрека (аудиопотока) несколько источников (то есть задача сложнее, чем из потока

шума получить какой-то один источник – в статье [11] приводится пример появления задачи – потребность услышать и вычленив из общего шума общественного места выделить голос и речь своего собеседника).

Таким образом, необходимо провести обзор и анализ методов разделения музыкальных источников, являющимися стандартами в наше время, определить возможные методы дообучения таких моделей, а также метрики, которыми можно оценить проведённое дообучение.

1.1 Постановка задачи

Задача извлечения источников из музыкального сигнала формулируется следующим образом [12]: «Дан звуковой файл в формате .wav, содержащий запись нескольких музыкальных инструментов. Звуковой файл представляет собой оцифрованный аналоговый сигнал $x(t)$. Необходимо найти аудиосигналы $\hat{s}_i$, удовлетворяющие следующим условиям».

$$\begin{cases} x(t) = \sum_{i=1}^N s_i(t) + n(t), \\ \hat{s}_i(t) = \mathcal{F}(x(t), i) \approx s_i(t), \end{cases}$$

где

- $x(t)$ — исходный смешанный аудиосигнал;
- $s_i(t)$ — эталонный аудиосигнал i -го источника;
- N — количество источников в композиции;
- $n(t)$ — шумовой компонент (помехи, внешние источники);
- $\mathcal{F}(x(t), i)$ — оператор извлечения i -го источника, реализуемый нейросетевой архитектурой;
- $\hat{s}_i(t)$ — аудиосигнал i -го источника, полученный оператором извлечения источников.

1.2 Вклад кампании SiSEC MUS 2018 в задачу разделения источников

В статье, посвящённой реализации нейронной сети Open-Unmix [13] упоминается крупная международная кампания SiSEC 2018 [14, 15], в рамках которой были стандартизированы подходы к оценке качества разделения аудиоисточников. Среди основных задач данной кампании была задача извлечения из профессионально записаной музыки музыкальных инструментов по следующим общим категориям:

- барабаны (drums),
- бас (bass),
- вокал (vocals),
- другие музыкальные инструменты и звуки (other).

В рамках кампании SiSEC Mus 2018 сообществом исследователей был сформирован эталонный набор данных MUSDB18 [16], содержащий 150 музыкальных композиций с разделенными аудио источниками в сумме составляющие 10-часовой плейлист. Набор данных MUSDB18 всё ещё является самым большим бесплатным набором в открытом доступе и активно используется в задачах дообучения нейронных сетей, решающих задачу разделения источников [11] (при необходимости или скудности материалов этого набора данных исследователи прибегают к самостоятельному сбору специфичных наборов данных [17]). Но чаще всего обучение больших базовых моделей, решающих задачу извлечения аудиоисточников, происходит именно на этом наборе.

1.3 Способы представления звукового сигнала для задачи разделения источников

Разные нейросетевые методы разделения музыкальных источников работают с разным представлением звукового сигнала. От того, какой способ был выбран, зависит эффективность самого метода и его архитектура. В современной литературе по цифровой обработке сигналов и машинному обучению выделяют три основных класса представлений [18, 19]:

- временное (waveform),
- частотное (spectral),
- частотно-временное (time-frequency).

1.3.1 Временное представление

Наиболее фундаментальным способом представления звука является дискретизированный временной сигнал $x[n]$, где $n = 0, 1, \dots, N - 1$ — номер отсчёта, N — общая длина сигнала. Значение $x[n]$ соответствует амплитуде звукового давления в момент времени $\frac{n}{f_s}$ где f_s — частота дискретизации (обычно 44100 Гц или 48000 Гц для музыкального контента) [20].

С точки зрения физики временной сигнал отражает колебание давления воздуха, которые были зафиксированы микрофоном, записывающим аудиосигнал. Монофонический звуковой сигнал (моносигнал) представляет

собой последовательность вещественных чисел $x[n]$, где каждый отсчёт отражает мгновенное значение амплитуды. Для удобства обработки значения обычно нормализуются к диапазону $[-1, 1]$ или сохраняются в стандартном цифровом формате РСМ (импульсно-кодовая модуляция) с фиксированной разрядностью (например, 16 или 24 бита). Именно такой формат данных лежит в основе несжатых форматов (.wav, .aiff), а также служит промежуточным представлением при декодировании сжатых форматов (.mp3, .aac) перед их обработкой нейросетевыми алгоритмами.

В задачах разделения источников временное представление используется в архитектурах, работающих во временной области, таких как Conv-TasNet [21] и Demucs [1, 11], которые работают непосредственно с сырыми отсчётами, применяя одномерные свёртки для извлечения признаков.

1.3.2 Частотно-временное представление

Большинство современных методов разделения музыкальных источников работают во частотно-временной области, применяя оконное преобразование Фурье (Short-Time Fourier Transform, STFT) для перевода исходного аудиосигнала в спектральное представление. Характерным примером такой архитектуры является модель Open-Unmix [13].

Оконное преобразование Фурье (ОПФ) вычисляется путём последовательного применения скользящего окна к дискретному сигналу $x[n]$. На каждом шаге фрагмент сигнала умножается на оконную функцию $w[n]$ и подвергается дискретному преобразованию Фурье. Окно сдвигается вдоль сигнала с заданным шагом, меньшим его длины [22]:

$$X[m, k] = \sum_{n=0}^{L-1} x[n + mH] \cdot w[n] \cdot e^{-j2\pi kn/L},$$

где

- $X[m, k] \in \mathbb{C}$ — комплексное значение ОПФ для сегмента m и частотного отсчёта k ;
- L — размер окна анализа (обычно 2048 или 4096 отсчётов);
- H — шаг окна, обычно $H = L/4$ или $H = L/2$;
- $w[n]$ — оконная функция;
- $k = 0, 1, \dots, L/2$ — индекс частотного отсчёта (соответствует частоте $f_k = k \cdot f_s/L$);
- $m = 0, 1, \dots, M - 1$ — индекс временного фрейма, где M — общее

число фреймов;

- j — мнимая единица.

С точки зрения физики, ОПФ отображает сигнал в трёхмерное пространство (время $\times$ частота $\times$ комплексная амплитуда), где каждое значение $X[m, k]$ характеризует вклад частоты $f_k = kf_s/L$ в момент времени $t_m = mH/f_s$.

Спектрограмма представляет собой двумерное представление сигнала, которое формируется на основе оконного преобразования Фурье (ОПФ) путём вычисления модуля или квадрата модуля его комплексных коэффициентов. В зависимости от цели анализа выделяют амплитудную и энергетическую спектрограммы:

$$S[m, k] = |X[m, k]| \quad (\text{амплитудная}),$$

$$P[m, k] = |X[m, k]|^2 \quad (\text{энергетическая}),$$

На практике для сжатия широкого диапазона аудиосигнала часто применяется логарифмическое масштабирование:

$$S_{\log}[m, k] = \log(1 + |X[m, k]|) \quad (\text{логарифмическая}).$$

Визуально спектрограмма представляет собой двумерное изображение (тепловая карта), где по оси абсцисс откладывается время, по оси ординат — частота, а яркость цвета на графике соответствует энергии соответствующей спектральной компоненты. Для музыкальных сигналов такая визуализация позволяет наглядно выделить гармоническую структуру инструментов, проявляющуюся в виде горизонтальных полос на частотах, кратных основной частоте тона. Пример спектрограммы музыкального сигнала приведён на рисунке 1.2.

В контексте задач разделения музыкальных источников спектрограмма служит в качестве основного входного представления для моделей, работающих в частотной области (например, Open-Unmix [13]). В рамках такого подхода нейросетевая архитектура обучается предсказывать матрицы частотно-временных масок $M_c[m, k] \in [0, 1]$ для каждого источника c , которые затем применяются к исходному аудиосигналу для выделения отдельных компонент источников:

$$\hat{S}_c[m, k] = M_c[m, k] \cdot S_{\text{mix}}[m, k],$$




Рисунок 1.2 – График спектрограммы музыкальной композиции. Авторский материал

где

- S_{mix} — спектрограмма исходного музыкального файла;
- $\hat{S}_c[m, k]$ — оценка спектрограммы c -го источника.

Для восстановления временного сигнала из спектрограммы применяется обратное ОПФ (*iSTFT*, *inverse STFT*) (формула 1.1).

$$\hat{x}[n] = \frac{1}{L} \sum_{m=0}^{M-1} \left(\frac{1}{2\pi} \sum_{k=0}^{L-1} \hat{X}[m, k] \cdot e^{j2\pi kn/L} \right) \cdot w[n - mH], \quad (1.1)$$

где $\hat{X}[m, k]$ — комплексная спектрограмма с применённой маской (сохраняется фаза исходной композиции или восстанавливается итеративными методами).

1.4 Обзор современных архитектур моделей разделения источников

Современные архитектуры извлечения аудиосисточников можно условно разделить на два основных класса в зависимости от того, в какой области они обрабатывают аудиосигнал: во временной области (Demucs [1]) или в частотной (Open-Unmix [13] и Spleeter [2]). Далее рассмотрим эти основные виды архитектур и сравним их способы реализации и применение.

1.4.1 Архитектура модели Open-Unmix

Архитектуры, работающие в частотной области (например, Open-Unmix [13] и Spleeter), основаны на предварительном преобразовании

входного временного аудиосигнала в спектрограмму с использованием оконного преобразования Фурье. В таком представлении каждый элемент матрицы спектрограммы соответствует амплитуде (энергии) конкретной частотной компоненты в заданный момент времени.

В процессе работы нейросетевая модель анализирует эту спектрограмму и предсказывает частотно-временные маски для каждого заданного источника. Далее полученная маска поэлементно умножается на спектрограмму исходного аудиомикса, после чего к результату применяется обратное оконное преобразование Фурье (iSTFT) для получения итоговой аудиодорожки источника.

Детальная структура модели Open-Unmix, которая является на текущей момент эталонной реализацией спектрального подхода, представлена в работе [13]. Схема ее архитектуры приведена на рисунке 1.3.




Рисунок 1.3 – Архитектура модели Open-Unmix. Авторский материал

Общая идея модели Open-Unmix заключается в преобразовании исходного файла аудиомикса музыкальных инструментов в формате спектрограммы в набор спектрограмм отделенных музыкальных инструментов-источников из этого микса.

Модель Open-Unmix состоит из следующих компонентов:

- 1) Предобработка данных — так как предобученная модель Open-Unmix обучалась на наборе данных MUSDB18 [16], аудиозаписи которого

подвергались AAC-сжатию, в результате которого диапазон спектрограмм обрезался до 16 кГц, в модели Open-Unmix на этапе предобработки входного сигнала выполняется «обрезка» спектрограммы по оси частот с исключением частотных ячеек, соответствующих более высоким частотам (больше 16 кГц).

- 2) Входная нормализация и масштабирование — блок обучаемых аффинных параметров. Он выполняет нормализацию входных спектрограмм для улучшения качества работы модели с помощью поэлементного сдвига и масштабирования входных спектрограмм, выравнивая распределение амплитуд по частотным каналам перед подачей на основные слои модели, что ускоряет сходимость градиентного спуска.
- 3) Блок кодирования признаков (кодировщик) — это совокупность механизмов и линейных слоёв внутри единой архитектуры Open-Unmix, которая занимается сжатием входного аудиопотока в компактный набор признаков — то есть выполняет проекцию высокоразмерного частотно-канального представления в компактное скрытое (латентное) пространство. В отличие от классических автоэнкодеров, данный блок не обучается восстанавливать вход, а формирует представление, оптимальное для последующего предсказания маски. В свою очередь модель кодировщика состоит из следующих блоков:

- Первый полносвязный слой (fc1, Fully Connected) — линейный слой без смещения, который выполняет сжатие частотно-канального пространства в представление «узкое горлышко», снижая избыточность данных и формируя компактный вектор признаков.

- Первый слой пакетной нормализации (bn1, Batch Normalization layer) — это обучаемый модуль, который выполняет стандартизацию выходных значений полносвязного слоя перед подачей на функцию активации. В архитектуре Open-Unmix данный слой обрабатывает 512-мерное векторное представление («узкое горлышко»), обеспечивая согласованность признаков перед их подачей на нелинейное преобразование tanh.

- Функция гиперболического тангенса (tanh) — нелинейная функция активации, ограничивающая значения активации диапазоном $[-1, 1]$, что необходимо для устойчивой работы рекуррентных слоёв.

Формула функции гиперболического тангенса имеет вид:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (1.2)$$

где x — входная активация слоя bn1.

- 4) Центральный модуль модели — блок, реализованный на основе двунаправленной долговременной краткосрочной памяти (Bidirectional Long Short-Term Memory, BLSTM). Данный модуль предназначен для выявления и учёта динамических взаимосвязей между временными отсчётами аудиосигнала, поскольку музыкальная запись характеризуется непрерывным изменением спектрального состава и амплитуды. Архитектурно блок BLSTM представляет собой последовательную цепь из трёх рекуррентных слоёв (обозначено как $\times 3$ на схеме 1.3).

Такая многослойная архитектура обеспечивает формирование признаков по принципу иерархии: начальные слои фиксируют кратковременные локальные особенности звучания (амплитудные огибающие, резкие переходные процессы), тогда как последующие слои последовательно интегрируют эти данные, выделяя более протяжённые музыкальные закономерности (мелодические фрагменты, гармонические последовательности, спектрально-тембровые характеристики).

Для устойчивого обучения глубокой рекуррентной сети и предотвращения потери исходных данных на промежуточных этапах применяется механизм *остаточного соединения* (*Skip Connection*). На схеме он изображён фиолетовой стрелкой над блоком «Двунаправленный рекуррентный слой» и обозначает объединение исходного входного тензора с результатом обработки блоком BLSTM. Математически это объединение описано в формуле 1.3:

$$h = x + \mathcal{F}_{\text{BLSTM}}(x), \quad (1.3)$$

где

- x — входное представление размера H (512),
- $\mathcal{F}_{\text{BLSTM}}(\cdot)$ — преобразование, выполняемое стеком BLSTM-слоёв.

Данный приём обеспечивает прямой градиентный поток, сохраняет низкоуровневую спектральную информацию и ускоряет сходимость оптимизатора без риска деградации представлений при увеличении глубины сети. То есть данные из начала блока копируются в конец,

минуя сложные вычисления. Это нужно, чтобы важная информация не потерялась при глубокой обработке.

- 5) Блок восстановления размерности (декодировщик) — набор механизмов и линейных слоёв, отвечающих за восстановление размерности тензора до пространства входной спектрограммы для последующего формирования маски. В отличие от декодера автоэнкодера, данный блок не обучается реконструировать исходный сигнал, а предсказывает коэффициенты маски, которые при поэлементном умножении на входной спектр выделяют целевой источник.

В конфигурации Open-Umix входят следующие компоненты:

- Второй и третий полносвязные слои (fc2 и fc3) — слой fc2 проецирует объединённый вектор признаков из расширенного пространства $2H$ обратно в компактное представление размера H , а слой fc3 расширяет его до исходного числа частотно-канальных коэффициентов, формируя основу для последующего вычисления весовой маски.

- Второй и третий слой пакетной нормализации (bn2 и bn3) — стабилизируют распределение сигналов внутри пакета на промежуточных этапах восстановления. Данная процедура выравнивает масштаб активаций, предотвращает «насыщение» нейронов и делает процесс обновления весов более устойчивым к колебаниям громкости входного аудиосигнала.

- Функция активации ReLU — функция применяется после нормализации и на финальном выходе блока. Формально функция определяется как:

$$\text{ReLU}(x) = \begin{cases} 0, & \text{если } x < 0, \\ x, & \text{если } x \geq 0, \end{cases} \quad (1.4)$$

где x — входная активация.

В отличие от ограниченных S -образных (сигмоидальных) функций, функция ReLU заменяет все отрицательные значения нулями. Это обеспечивает два важных свойства: во-первых, модель фокусируется только на значимых признаках, подавляя фоновый шум; во-вторых, гарантируется неотрицательность итоговой маски, что соответствует физической природе амплитудного спектра, потому что интенсивность частотных компонент не может принимать отрицательные значения.

6) Мультипликативное остаточное соединение (маскирование) (Multiplicative Skip-Connection) — механизм финального выделения целевого источника, при котором исходный спектр аудиомикса X минуя основные слои сети и поэлементно умножается на предсказанную маску $\hat{M}$ только на выходе. Такой подход предпочтительнее прямой генерации спектрограммы «с нуля», так как позволяет переиспользовать фазовую информацию из исходного сигнала, избегая артефактов реконструкции. Модель Open-Unmix вычисляет широкополосную маску (full-band mask) $\hat{M}$, значение которой в каждом частотно-временном элементе (бине, bin) отражает долю энергии целевого источника в общем аудиомиксе. Процесс итогового разделения описывается формулой поэлементного умножения:

$$\hat{S} = X \odot \hat{M}, \quad (1.5)$$

где

- $X \in R^{T \times F}$ — исходная входная спектрограмма аудиомикса (суммарное представление всех инструментов),
- $\hat{M} \in R^{T \times F}$ — предсказанная нейросетью маска (выход модуля декодирования после функции активации ReLU, обеспечивающей неотрицательность значений),
- $\hat{S}$ — результирующая спектрограмма целевого источника (например, вокала или гитары).

Таким образом, архитектура Open-Unmix реализует сквозной конвейер частотно-временного разделения источников, в котором входная спектрограмма аудиомикса последовательно проходит через блок кодирования признаков, двунаправленную рекуррентную сеть для моделирования временных зависимостей и блок восстановления размерности, формирующий оценку маски для извлечения целевого сигнала. Финальное выделение изолированной дорожки осуществляется путём поэлементного умножения предсказанной маски на исходную спектрограмму, что обеспечивает восстановление целевого источника с сохранением фазовой информации и минимизацией артефактов, характерных для генеративных моделей.

Модель Open-Unmix имеет как преимущества, так и недостатки среди моделей, решающих задачу разделения источников. Среди преимуществ можно отметить:

- 1) Высокая воспроизводимость и открытость. Авторы модели Open-Unmix

называют ей эталонной реализацией [13] для задач разделения источников. Текст исходной программы, предобученные веса и документация находятся в открытом доступе, что обеспечивает полную воспроизводимость результатов и упрощает интеграцию в исследовательские и прикладные проекты.

- 2) Эффективное моделирование временного контекста. Применение двунаправленной LSTM-сети (BLSTM) позволяет модели учитывать как предшествующий, так и последующий контекст относительно текущего фрейма [28]. Это преимущество важно для разделения гармонически насыщенных сигналов, где выделение источника часто требует анализа музыкальной фразы целиком.
- 3) Баланс качества и вычислительной сложности. Архитектура демонстрирует конкурентоспособное качество на эталонных наборах данных (например, MUSDB18) при умеренных требованиях к ресурсам по сравнению с более тяжёлыми генеративными моделями. Этот принцип делает модель пригодной для обработки без требований реального времени и моделирования при отсутствии больших вычислительных мощностей.
- 4) Модульность и расширяемость. Чёткое разделение на блоки кодирования, рекуррентной обработки и декодирования позволяет адаптировать архитектуру под специфические задачи: замену BLSTM на Transformer, добавление многозадачного обучения или расширение на новые классы источников.

Но модель Open-Unmix также имеет следующие ограничения:

- 1) Вычислительная сложность рекуррентных слоёв. Последовательная природа LSTM-ячеек ограничивает возможности параллелизации при обучении и применении. Обработка длинных аудиопоследовательностей требует значительного времени и памяти, что затрудняет применение модели в системах реального времени с низкой задержкой.
- 2) Допущение о независимости источников. Подход на основе идеальных масок (Ideal Ratio Mask) предполагает, что источники в аудиомиксов аддитивны и слабо коррелированы. В случаях сильного спектрального перекрытия (например, вокал и соло-гитара в одном частотном диапазоне) качество разделения может снижаться из-за компромиссов при оценке маски.
- 3) Отсутствие явного моделирования фазы. Поскольку маска применяется

только к магнитуде спектрограммы, фазовая информация копируется из аудиомикса без коррекции. Это может приводить к остаточным артефактам («фазовый шум») в областях, где целевой источник и интерференция имеют близкие частоты, но противоположные фазы.

Архитектура Open-Unmix представляет собой сбалансированное решение для задачи разделения музыкальных источников, сочетающее интерпретируемость, воспроизводимость и конкурентоспособное качество. Основные ограничения модели связаны с вычислительной сложностью рекуррентных блоков и допущениями, лежащими в основе подхода маскирования.

1.4.2 Архитектура модели Spleeter

Модель Spleeter — это система разделения музыкальных источников, разработанная компанией Deezer в 2019 году [2]. Модель основана на архитектуре U-Net [23], работающей в частотной области, и обучена на синтетически сгенерированном наборе данных из 25 тысяч композиций. В отличие от рекуррентных подходов (Open-Unmix), модель Spleeter использует полностью сверточную архитектуру типа U-Net, что обеспечивает высокую скорость обработки за счёт параллелизации вычислений.

Модель Spleeter поддерживает разделение на 2, 4 или 5 источников (вокал, барабаны, басы, пианино, «другое»), что делает её одной из первых промышленных систем, ориентированных на широкое применение.

Архитектура модели Spleeter в соответствии с документацией [29] включает следующие компоненты:

- 1) Входное представление. Входной аудиосигнал $x(t)$ преобразуется в комплексную спектрограмму с помощью оконного преобразования Фурье с окном 4096 и шагом 1024.
- 2) Энкодер (Encoder). Энкодер извлекает иерархические признаки из входной спектрограммы с помощью последовательности сверточных блоков. Каждый блок включает:
 - Свертку 3×3 с шагом 2 (downsampling);
 - Пакетную нормализацию (Batch Normalization);
 - Функцию активации ReLU.
- 3) Блок сжатия (bottleneck — «горлышко бутылки», узкое место) — это центральный блок слоёв, в котором формируется наиболее сжатое представление признаков. Такое сжатие позволяет модели выделять

наиболее существенные абстрактные характеристики музыкального сигнала, отфильтровывая шум и несущественные детали.

- 4) Декодер с пропущенными связями. Декодер восстанавливает пространственное разрешение признаков с помощью транспонированных сверток (Transposed Convolution).
- 5) Выходной слой и маскирование. Выход модели представляет собой маску, применяемую к исходной спектрограмме для извлечения целевого источника. Обратное преобразование Фурье используется для восстановления временного сигнала.

Модель Spleeter имеет следующие преимущества:

- 1) Высокая скорость выполнения запроса. Благодаря полностью сверточной архитектуре без рекуррентных связей, все вычисления могут быть распараллелены на GPU. Обработка трека происходит в 5–10 раз быстрее, чем в реальном времени, что делает модель пригодной для потоковых сервисов.
- 2) Эффективное сохранение деталей. Архитектура модели Spleeter, основанная на модели U-Net с механизмом skip-connections позволяет восстанавливать высокочастотные компоненты, которые часто теряются в архитектурах с сильным сжатием, обеспечивая «прозрачное» звучание.
- 3) Устойчивость к переобучению. Использование пакетной нормализации и умеренной глубины сети (по сравнению с Transformer-моделями) снижает риск переобучения на небольших наборах данных.

Также существуют значимые ограничения в работе модели Spleeter:

- 1) Частотные артефакты. Работа исключительно в магнитудной области с сохранением фазы из аудиомикса приводит к артефактам в областях сильного спектрального перекрытия источников.
- 2) Малая гибкость архитектуры. Фиксированная структура U-Net сложнее адаптируется под новые классы источников или многозадачное обучение по сравнению с модульными подходами (Open-Unmix, Demucs).
- 3) Модель Spleeter является устаревшей и не применяется в современных исследованиях в связи с тем, что больше не поддерживается разработчиками. У модели сохраняются зависимости от устаревших версий библиотек Python, что становится проблемой при исследовании.

1.4.3 Архитектура модели Demucs

В статье [1] разработчики социальной сети Facebook описывают новый подход к методу извлечения источников. Demucs (Hybrid Transformer Demucs) на данный момент является одним из стандартов индустрии (SOTA — state of the art) задачи извлечения источников.

Demucs [1] – это нейронная сеть глубокого обучения, которая была разработана для решения задачи выделения аудио-источников. В основе нейросети Demucs лежит свёрточная нейронная сеть UNet [23], которая используется для семантической сегментации изображений. То есть Demucs использует подход сети Unet обработки изображений и применяет для обработки волн аудиосигнала по спектрограммам [1].

В статье музыкальная композиция сравнивается с коктейльной вечеринкой, где каждый голос, фоновая мелодия и шум – каждый этот элемент является стемом, и тогда задача выделения голоса собеседника, с которым ведется диалог на вечеринке, является как раз задачей разделения источников. Но задача выделения источников из музыкальной композиции отличается от задачи выделения голоса собеседника на в первую очередь тем, что в ней интересует в этой задаче выделение не какого-то одного приоритетного источника звука из несвязанного фонового шума, а целый набор тонов и тембров в согласованном потоке.

Разработчики модели Demucs основываются на архитектуре Conv-Tasnet и адаптируют ее под извлечение источников, т.к. изначально модель Conv-Tasnet предназначалась для извлечения речи из аудиопотока [21].

Модель Demucs (в актуальных версиях v3/v4 [1]) представляет собой гибридную архитектуру, объединяющую свёрточные нейронные сети, трансформерные блоки и параллельную обработку аудиосигнала как во временной области (waveform domain), так и в частотной (спектрограмма на основе ОПФ). В отличие от традиционных методов, которые предсказывают только амплитудные маски, Demucs одновременно анализирует амплитуду и фазу сигнала. Это позволяет точнее восстанавливать временную структуру звука и избегать характерных искажений, возникающих при простом умножении спектра на маску. Архитектура модели Demucs представлена на рисунке 1.4.

Модель Demucs состоит из следующих основных компонент:

- 1) Гибридный энкодер. Входной сигнал $x(t)$ преобразуется в скрытое представление (латентные признаки) с помощью одномерных




Рисунок 1.4 – Схема архитектуры модели Demucs. Авторский материал

сверточных слоев (1D Convolution). В отличие от чистых временных моделей, Demucs также извлекает признаки из спектрограммы того же сигнала. Это позволяет модели использовать преимущества обеих областей: временную точность и частотную структуру.

- 2) Блок разделения. Полученные признаки подаются на вход слоя, состоящего из Transformer-блоков. В отличие от LSTM в Open-Unmix, механизм «самовнимания» (Self-Attention) позволяет модели захватывать глобальный контекст всей композиции, эффективно разделяя источники с длинными зависимостями. Внутри блока применяется маскирование или прямое оценивание источников.
- 3) Гибридный декодер (Hybrid Decoder). Разделенные латентные представления преобразуются обратно в звуковую волну с помощью транспонированных одномерных сверток (Transposed Convolution). Декодер также работает в двух областях: он восстанавливает временной сигнал и частотное представление, которые затем суммируются.
- 4) Гибридная функция потерь. Обучение оптимизирует ошибку одновременно в двух областях: во временной (функции потерь L_1/L_2) и частотной (функции потерь L_1/L_2 по спектрограмме). Это заставляет модель генерировать сигнал, который звучит естественно (временная область) и имеет правильную спектральную структуру (частотная область).

Модели, работающие во временной области, такие как Demucs, обрабатывают аудиосигнал непосредственно в виде последовательности амплитудных значений (волн). Их главное преимущество заключается в сохранении полной информации о сигнале, включая фазовые характеристики, что критически важно для точного воспроизведения резких атак нот, характерных для многих инструментов, включая гитару и ударные.

Также к преимуществам модели Demucs относятся:

- 1) Высокое качество разделения. Модели Demucs демонстрирует одни из лучших результатов на эталонных наборах данных (например, MUSDB18), превосходя LSTM-подходы (Open-Unmix) по метрикам SDR (Signal-to-Distortion Ratio) и SAR (Signal-to-Artifact Ratio).
- 2) Глобальный контекст. Использование механизма самовнимания позволяет учитывать структуру музыкального произведения на больших промежутках времени, эффективно разделяя источники с похожими тембрами.
- 3) Гибридная оптимизация. Совместное обучение на временных и частотных потерях обеспечивает баланс между восприятием сигнала на слух и точностью спектрального разделения.

Но у модели Demucs также есть значительные ограничения, которые создают препятствия по использованию модели в исследовательских работах:

- 1) Вычислительная сложность. Архитектура Transformer имеет квадратичную сложность $O(N^2)$ по отношению к длине последовательности, что требует значительных ресурсов видеопамати и времени для инференса по сравнению с Open-Unmix.
- 2) Большое количество параметров. Demucs v4 содержит сотни миллионов параметров, что затрудняет развертывание модели на мобильных устройствах или встраиваемых системах без дополнительных методов компрессии.
- 3) Галлюцинации и артефакты. В случаях при сильном перекрытии источников трансформер может генерировать несуществующие звуковые артефакты, пытаясь «заполнить» пробелы в спектре.

1.5 Анализ методов дообучения предобученных моделей разделения источников

Существуют задачи, в рамках которых средств существующих предобученных нейронных сетей недостаточно и возникает потребность

провести над выбранной нейронной сетью ряд действий, позволяющих «научить» её тому контексту, которому она не была «обучена» ранее, в процессе основного обучения, и которого не хватает для решения специфичной исследовательской задачи. При этом чаще всего такое обучение требуется провести без утраты тех «знаний», которым была обучена модель первоначально, так как повторное переобучение модели с нуля — дорогостоящий процесс, требующий больших вычислительных мощностей, больших наборов данных, настройки всех параметров и т.д.

В таких случаях современные исследователи прибегают к подходу дообучения модели, в рамках которого модель не требуется переобучать заново, но необходимо провести её «тонкую настройку» (fine-Tuning) [31, 33] — то есть на уровне механики модели провести некоторые действия, чтобы научить нейронную сеть новым концептам с максимальным сохранением предыдущего накопленного опыта.

В случае задачи разделения источников в аудиосигнале обучение предобученной архитектуры модели с открытым исходным кодом на целевом наборе данных позволяет адаптировать модель к специфическим классам источников, о которых модель не «знала» и которые не умела извлекать до этого, без необходимости обучения «с нуля».

Метод «тонкой настройки» в настоящее время широко применяется на различных предобученных нейросетевых моделях, включая модели извлечения аудиоисточники. В зависимости от вычислительных ограничений и объёма данных для решения задачи дообучения применяется одна из трех основных стратегий: полная тонкая настройка, частичная настройка выходного блока и адаптация низкого ранга [32].

1.5.1 Полное дообучение

Полное дообучение представляет собой стратегию обновления всех весов предобученной модели на новом, целевом наборе данных (например, полное дообучение применялось в работе [34]). Все параметры предобученной модели размораживаются, и оптимизатор обновляет веса всех слоёв на новом наборе данных. Обучение проводится с пониженным коэффициентом обучения (learning rate), чтобы не разрушить уже усвоенные при первичном обучении спектрально-временных представлений, но позволить сети адаптироваться к новому распределению данных.

В контексте задач разделения музыкальных источников данный подход

подразумевает дообучение всей архитектуры на целевом наборе данных, содержащем изолированные партии инструментов, отсутствующие в исходном распределении модели. На предварительном этапе конфигурация выходного слоя адаптируется под новое количество источников, после чего оптимизатор обновляет веса всех слоёв сети, обеспечивая полную адаптацию внутренних спектрально-временных представлений к специфике целевых классов.

Основное преимущество данного подхода — максимальная гибкость адаптации модели к специфике задачи, в том числе к особенностям частотного диапазона и перекрытию гармоник между инструментами. Также к преимуществам можно отнести:

- 1) Простота реализации, метод не требует модификации архитектуры, чаще всего достаточно внести небольшое количество изменений.
- 2) При достаточном объёме наборов данных данный метод демонстрирует хорошее качество разделения источников [1, 35].

Несмотря на высокую эффективность, стратегия сопряжена с существенными вычислительными и методическими ограничениями. Полное обновление весов требует значительного объёма видеопамати для хранения градиентов и состояний оптимизатора, что часто делает процесс недоступным в средах с ограниченным аппаратным бюджетом [7]. Кроме того, метод критически зависит от объёма и качества целевой выборки: при недостатке данных высок риск переобучения на специфичные акустические условия записей, а некорректно подобранные гиперпараметры могут привести к катастрофическому забыванию базовых признаков. В связи с этим полное дообучение целесообразно применять при наличии достаточных вычислительных ресурсов и сбалансированного набора данных.

1.5.2 Методы «параметрического» дообучения (адаптация части параметров)

Существует класс методов, которые отталкиваясь от концепции метода полного дообучения, дообучают не полностью всю модель, а только часть её весов: замораживают основную массу весов предобученной модели и обучают лишь малую добавочную часть параметров (обычно < 5% от общего числа). Такие методы называют «частичным дообучением» или «параметрически эффективная адаптация» [36].

Суть метода заключается в том, что все слои кодировщика и

рекуррентного/сверточного блока, размораживается только выходной слой (декодировщик или классификационная «голова», выходной слой) [33]. Модель использует предобученные признаки общего звукового представления, а перестраивается только механизм соответствия признаков в целевые маски источников [33].

Преимущества параметрически эффективной адаптации перед полным дообучением заключаются в следующем:

- 1) Существенное снижение требований к вычислительным ресурсам и времени обучения, поскольку в процессе оптимизации обновляется лишь малая часть параметров модели [33].
- 2) Высокая устойчивость процесса настройки: основные слои сети сохраняют свои веса, что предотвращает утрату ранее усвоенных общих акустических закономерностей [30, 33].
- 3) Удобство практического применения: экономия ресурсов позволяет быстро проверять различные варианты подготовки обучающей выборки и подбирать оптимальные параметры без длительных вычислений [33].

Несмотря на перечисленные достоинства, методы данного класса имеют ряд ограничений:

- 1) Ограниченная глубина адаптации: если целевые инструменты существенно отличаются по спектральным характеристикам от тех, на которых изначально обучалась базовая часть модели, качество разделения может оказаться недостаточным, поскольку основные внутренние преобразователи сигналов остаются неизменными [30].
- 2) Сниженная эффективность при работе с данными, кардинально отличающимися от исходных. Например, модель, оптимизированная под чистые студийные записи, может демонстрировать низкое качество при обработке концертных выступлений или аудиоматериалов с высоким уровнем постороннего шума и артефактов сжатия [30].

1.5.3 Адаптация низкого ранга (LoRA, Low Rank Adaptaion)

Метод LoRA (Low Rank Adaptaion — дословно переводится как «адаптация на основе низкого ранга») был разработан для больших языковых генеративных моделей [7], но нашёл применение в большом пласте работ по дообучению моделей в машинном обучении, например, активно используется при дообучении генеративных моделей [37]. Этот метод — наиболее распространённая реализация парадигмы параметрически эффективного

дообучения.

Основное отличие LoRA от методов полного дообучения и частичного дообучения заключается в том, что здесь адаптируется некоторое количество параметров, результатом метода LoRA являются те веса, которые были преобразованы. Низкоранговые методы дообучения основаны на идее замены части весов матриц на низкоранговые приращения, которые обучаемы, а исходные веса при этом остаются неизменными. Подход LoRA схематично представлен на рисунке 1.5.

Суть подхода LoRA представлена в названии метода: исследователи при создании этого метода проверяли гипотезу, которая заключалась в том, что внутренняя размерность (ранг) матрицы весов $\Delta W = W_{fine_tuning} - W_0$ (где W_{fine_tuning} — веса модели после дообучения, W_0 — веса исходной модели) в больших моделях обладает низким рангом, несмотря на то, что исходная матрица весов W_0 имеет полный ранг. Это явление объясняется избыточной параметризацией современных нейросетей [38]: число обучаемых параметров значительно превышает минимально необходимое для решения задачи, что позволяет оптимизатору концентрировать полезные градиенты в низкоранговом подпространстве без потери обобщающей способности (то есть «предыдущих знаний»).

Такое предположение позволяет декомпозировать изменение весов в виде произведения двух матриц более низкого ранга, чем матрица весов (а не оптимизировать саму матрицу весов изменяемого слоя):

$$\Delta W = BA,$$

где

- $A \in R^{r \times k}$ — матрица размерности $r \times k$,
- $B \in R^{d \times r}$ — матрица размерности $d \times r$,
- $r \ll \min(d, k)$ — ранг матрицы W , должен быть как можно меньше.

В процессе дообучения методом LoRA корректируются только матрицы A и B (считаются их градиенты и обновляются), что позволяет существенно снизить объём обучаемых параметров и требования к памяти GPU. Модель обучается лишь в низкоранговом подпространстве, которое описывается этими низкоранговыми матрицами, причём веса модели W_0 замораживаются и не преобразуются. Для получения итогового результата матрицы складываются:




Рисунок 1.5 – Схема обучения модели подходом LoRA. Авторский материал

$$y = W_0x + \Delta Wx = W_0x + BAx, \quad (1.6)$$

где

- A инициализируется Гауссовским распределением $A = N(0, \sigma^2)$,
- B инициализируется 0,
- W_0 — исходная матрица обучаемой модели.

Таким образом, LoRA заменяет полное обновление весов на обучение только компактных адаптеров, что сокращает количество обновляемых параметров на 70–91% [7], снижает потребление видеопамати и минимизирует риск катастрофического забывания исходных знаний модели, который часто сопутствует методам полного дообучения. В задаче выделения аудио источников, метод LoRA может применяться к отдельным слоям или компонентам модели (например, слоям свёртки или частотно-временным модулям), что позволяет выполнять адаптацию параметров без изменения архитектуры исходной сети.

Среди преимуществ метода разработки LoRA приводят следующие [7]:

- 1) Адаптеры LoRA небольшого размера, в связи с чем требования к размеру ресурсов для их расположения достаточно снижены.

- 2) Сниженные требования к видеопамяти. Метод не предусматривает выполнение тяжёлых операций расчёта градиентов для большинства параметров модели, следовательно, подход менее ресурсозатратен и поддерживает минимальные требования к железу. Это позволяет проводить эксперименты с крупными архитектурами в средах с ограниченными ресурсами (например, Google Colab в бесплатной версии).
- 3) Модульность и возможность переиспользования. Веса адаптеров A и B хранятся отдельно от базовой модели и могут быть дополнительно загружены или заменены без внесения изменений в архитектуру исходной модели. В рамках задачи извлечения источников, это позволяет поддерживать библиотеку адаптеров для различных инструментов (пианино, гитара, вокал) и комбинировать их при запуске модели.
- 4) Отсутствие катастрофического забывания. Заморозка исходных весов W_0 сохраняет знания, усвоенные моделью на этапе предобучения.

Также можно отметить следующие ограничения метода:

- 1) Необходимость подбора ранга r . Значение ранга r является гиперпараметром, требующим эмпирической настройки. Слишком малое r может ограничивать способность адаптации, а чрезмерно большое r нивелирует преимущества метода по экономии параметров и памяти при его использовании.
- 2) Ограничения при больших различиях в данных. Гипотеза о низком ранге обновлений ΔW может нарушаться при адаптации к задачам, радикально отличающимся от распределения данных предобучения (например, переход от студийных записей к полевым записям с низким соотношением сигнал/шум). В таких случаях полное дообучение может демонстрировать более высокую точность и быть более эффективным решением.

1.6 Метрики оценки качества (SDR, SIR, SAR)

В основных исследованиях, направленных на изучение дообучения моделей разделения источников, полученные результаты оцениваются при помощи метрик, которые являются стандартами в части оценки [4].

Для объективной оценки качества разделения источников для сравнения соответствующих методов применяются метрики, основанные на сравнении

предсказанных сигналов $\hat{s}_k$ с эталонными источниками s_k . Данная методология предполагает разложение общей ошибки на две независимые составляющие: влияние компонентов посторонних источников в исходном аудиосигнале (интерференция) и искажения, внесённые алгоритмом разделения (артефакты). Такой подход позволяет независимо оценивать два аспекта качества: эффективность подавления посторонних сигналов (инструментов, шумов) и чистоту извлечения целевого источника (насколько естественно звучит исходный источник).

В данной работе используются метрики семейства BSS Eval (Blind Source Separation Evaluation) [4] и их модификация SI-SDR. Набор оценочных метрик формировался в соответствии с методологией оригинальных исследований сравниваемых архитектур: для Open-Unmix [13] основным показателем выступает SDR, для Demucs [1] применяются SDR, SIR и SAR, а для Spleeter [2] используется полный набор метрик BSS Eval (SDR, SIR, SAR). Такой подход обеспечивает методологическую согласованность и корректность сравнительного анализа в рамках принятых в предметной области стандартов.

1.6.1 Декомпозиция сигнала по методу BSS Eval

Согласно методологии оценки сигнала BSS Eval [4], восстановленный сигнал аудиоисточника $\hat{s}$ может быть представлен в виде суммы независимых друг от друга составляющих в соответствии с формулов 1.7:

$$\hat{s} = s_{\text{target}} + e_{\text{interf}} + e_{\text{noise}} + e_{\text{artif}}, \quad (1.7)$$

где

- $\hat{s}$ — сигнал, полученный алгоритмом извлечения аудиоисточников;
- s — эталонный сигнал исходного аудиоисточника;
- s_{target} — компонента, представляющая собой проекцию сигнала $\hat{s}$ на пространство истинного сигнала s ;
- e_{interf} — компонента интерференции (другие посторонние источники, не относящиеся к источнику s);
- e_{noise} — компонента шума (фоновый шум, шум оборудования, не связанный с источниками);
- e_{artif} — компонента артефактов (искажения, внесённые алгоритмом).

В условиях отсутствия явного шума в наборах данных компонента e_{noise} часто пренебрегается и объединяется с компонентой e_{artif} , так как оба

слагаемых представляют собой «нежелательную» часть сигнала, не относящуюся ни к целевому источнику, ни к интерференции. При вычислении метрик SDR, SIR, SAR в популярной библиотеке `mir_eval`, шум e_{noise} часто не выделяется отдельно, если не задан эталонный сигнал шума.

В рамках данного исследования, использующего набор данных без явного фонового шума (например, MUSDB18 является такой коллекцией данных), компонента e_{noise} считается пренебрежимо малой и объединяется с компонентой артефактов. Таким образом, для расчёта метрик применяется упрощённая декомпозиция: $\hat{s} \approx s_{\text{target}} + e_{\text{interf}} + e_{\text{artif}}$.

На основе этой декомпозиции вычисляются три основные метрики (в децибелах, дБ), каждая из которых характеризует определённый аспект качества разделения: SDR отражает общее отношение полезного сигнала к сумме всех ошибок, SIR измеряет эффективность подавления интерферирующих источников, а SAR оценивает уровень артефактов, внесённых алгоритмом обработки.

Метрика *SDR* (*Signal-to-Distortion Ratio*, отношение сигнала к искажению), является интегральной метрикой, оценивающей общее качество разделения с учётом всех типов ошибок (например, наличие артефактов и наложения на источник других аудиоисточников).

Метрика отвечает на вопрос «Насколько сильно оценённый сигнал отличается от идеального, учитывая все возможные источники ошибок?». Метрика вычисляет отношение энергии компоненты s_{target} к суммарной энергии всех ошибок, возникающих в процессе разделения. Формула 1.8 описывает математическое определение метрики SDR:

$$\text{SDR} = 10 \log_{10} \left(\frac{\|s_{\text{target}}\|_2}{\|e_{\text{interf}} + e_{\text{artif}}\|_2} \right), \quad (1.8)$$

где $\|\cdot\|_2$ — Евклидова норма вектора дискретного сигнала.

Значение метрики выражается в децибелах (дБ). Чем выше значение метрики SDR, тем лучше качество полученного источника. Значение 0 дБ означает равенство энергии сигнала и энергии ошибок; положительные значения указывают на преобладание полезного сигнала. Увеличение значения метрики SDR на 10 дБ соответствует десятикратному улучшению отношения сигнал/шум. В исследованиях по разделению музыки [1, 2, 13] метрика SDR служит основным показателем для сравнения моделей.

Метрика *SIR* (*Signal-to-Interference Ratio*, отношение сигнала к

интерференции) измеряет способность модели подавлять другие источники в исходном аудиопотоке. Эта метрика игнорирует артефакты и шум, фокусируясь исключительно на «чистоте» разделения: насколько хорошо алгоритм отделил, например, вокал от аккомпанемента. Высокий SIR означает, что в выделенной дорожке практически не слышно других инструментов. Формула 1.9 описывает математическое определение метрики SIR:

$$\text{SIR} = 10 \log_{10} \left(\frac{\|s_{\text{target}}\|_2}{\|e_{\text{interf}}\|_2} \right). \quad (1.9)$$

Высокие значения SIR (например, >10–15 дБ) свидетельствуют об эффективном разделении источников. Однако высокий SIR не гарантирует высокого субъективного качества: сигнал может быть «чистым» от других инструментов, но при этом содержать сильные артефакты обработки (эффект «под водой», фазовые искажения), которые метрика SIR не учитывает.

Метрика SAR (*Signal-to-Artifacts Ratio*, отношение сигнала к артефактам) оценивает «чистоту» обработки сигнала самим алгоритмом, игнорируя наличие остатков других источников. Метрика чувствительна к искажениям, которые вносит метод разделения: эхо, фазовые сдвиги, «музыкальный шум», спектральные разрывы. Фактически, значение метрики SAR показывает, насколько естественно звучит выделенный источник, если абстрагироваться от того, что в нём могут присутствовать другие инструменты. Формула 1.10 описывает математическое определение метрики SAR:

$$\text{SAR} = 10 \log_{10} \left(\frac{\|s_{\text{target}} + e_{\text{interf}}\|_2}{\|e_{\text{artif}}\|_2} \right). \quad (1.10)$$

Низкие значения метрики SAR часто указывают на наличие слышимых артефактов, даже если значение общей метрики SDR высоко. Для задач, где важно естественное звучание (например, реставрация или улучшение качества), SAR является критически важным показателем. В методах, преобразующих входной аудиосигнал в частотно-временное представление с помощью ОПФ (Open-Unmix [13], Spleeter [2] и др.), низкое значение метрики SAR может указывать на артефакты, возникающие при некорректном применении маски к спектрограмме.

1.6.2 Метрика SI-SDR, масштабно-инвариантное отношение сигнала к искажению

Классические метрики чувствительны к глобальному масштабу (громкости) сигнала: если модель выдаёт правильный по форме, но более тихий сигнал, значение метрики SDR будет занижено.

Метрика *SI-SDR* (*Scale-Invariant SDR, масштабно-инвариантное отношение сигнала к искажению*) устраняет эту зависимость, предварительно нормализуя оценённый сигнал по энергии относительно эталона. Метрика оценивает исключительно сходство формы сигнала, игнорируя разницу в громкости.

Пусть s — эталонный сигнал, $\hat{s}$ — оцениваемый сигнал. Определим проекцию оценки $\hat{s}$ на направление эталонного сигнала s :

$$\alpha = \frac{\langle \hat{s}, s \rangle}{\|s\|_2}, \quad s_{\text{proj}} = \alpha s,$$

где

- $\langle \cdot, \cdot \rangle$ — скалярное произведение,
- α — оптимальный коэффициент масштабирования.

Тогда ошибка оценивается следующим образом:

$$\text{SI-SDR} = 10 \log_{10} \left(\frac{\|s_{\text{proj}}\|_2}{\|s_{\text{proj}} - \hat{s}\|_2} \right).$$

Оценка SI-SDR особенно полезна для моделей, работающих непосредственно во временной области, таких как Demucs или Conv-TasNet [1], где выходная амплитуда может варьироваться в процессе обучения. Кроме того, метрика является дифференцируемой, что позволяет использовать её непосредственно в качестве функции потерь при обучении нейронных сетей.

1.7 Выводы

В настоящей главе была систематизирована теоретическая база, необходимая для проведения исследования в области разделения музыкальных источников. Рассмотрены основные способы представления аудиосигнала, включая временную и частотно-временную области, а также математическое определение оконного преобразования Фурье, лежащее в основе формирования спектрограмм. Проведён обзор современных нейросетевых архитектур разделения источников, выявлены их особенности и

ограничения. Изучены стратегии дообучения предобученных нейросетевых моделей, сопоставлены подходы полного дообучения и параметрически эффективной настройки, а также проанализирован математический аппарат объективных метрик оценки качества разделения.

Проведённый в главе теоретический анализ позволил произвести выбор моделей и стратегий дообучения для дальнейшего исследования. Среди рассмотренных архитектур наиболее перспективными представляются Open-Unmix и Demucs с исходным кодом, а также за счёт модульной структурой и подтверждённой эффективностью в задачах разделения гармонических источников. Модель Spleeter исключается из дальнейшего рассмотрения ввиду её устаревшей архитектуры и зависимости от неподдерживаемых версий библиотек.

На основе проведённого анализа стратегий дообучения для выбранных моделей предложено применить подходы следующим образом: к гибридной трансформерной архитектуре Demucs целесообразно использовать метод параметрически эффективной настройки низкого ранга (LoRA), тогда как для Open-Unmix оптимальным решением выступает полное обновление параметров сети. Таким образом, теоретический обзор сформировал критерии для перехода к экспериментальному этапу работы.

2 РЕАЛИЗАЦИЯ И ПРОЕКТИРОВАНИЕ АРХИТЕКТУРЫ ПРОГРАММНОГО ОБЕСПЕЧЕНИЯ

На основе теоретического анализа первой главы были сформированы требования к архитектуре программной системы дообучения моделей извлечения источников. Данная глава посвящена проектированию и реализации конвейера дообучения, поддерживающего различные стратегии оптимизации для соответствующих архитектур в соответствии с их архитектурными и вычислительными особенностями. Основным решением стало применение к гибридной трансформерной архитектуре модели Demucs параметрически эффективной настройки LoRA, а для рекуррентной модели Open-Unmix, работающей в спектральной области, реализовать полное обновление параметров сети. Выбор обусловлен различиями в структуре моделей.

Метод LoRA эффективно работает со слоями внимания и линейными проекциями в архитектуре Demucs, позволяя адаптировать крупную сеть при минимальном количестве обучаемых параметров. В случае Open-Unmix основу вычислений составляют рекуррентные блоки BLSTM. Прямое применение низко-ранговых адаптеров к рекуррентным слоям требует сложной модификации алгоритма обратного распространения ошибки и не гарантирует стабильной сходимости на малых объёмах данных. Поэтому полное дообучение является наиболее надёжным и воспроизводимым вариантом для корректной настройки временных зависимостей под специфику целевого набора данных.

В последующих разделах главы подробно описывается структура модулей системы дообучения: подготовки и обработки данных, алгоритмы интеграции LoRA-адаптеров в слои трансформеров модели Demucs, конфигурация алгоритмов полного дообучения рекуррентной сети Open-Unmix, а также механизмы обеспечения стабильности обучения, логирования и сохранения обученных моделей.

2.1 Общая схема взаимодействия компонент разрабатываемой системы

Реализованная система дообучения спроектирована по модульному принципу с чётким разделением ответственности между компонентами подготовки данных, адаптации архитектуры, оптимизации и оценки качества. Архитектура системы включает три основные внутренние подсистемы:

- модуль работы с набором данных,
- модуль адаптации и запуска моделей,
- модуль проведения экспериментов и оценки результатов,
- модуль интеграции с внешними платформами для обеспечения воспроизводимости всего процесса эксперимента — от загрузки сырых данных до публикации готовых дообученных моделей.

Схема взаимодействия модулей представлена на рисунке 2.1. На схеме для каждого модуля приведен набор содержащихся внутри него классов и взаимодействие их между собой.




Рисунок 2.1 – Диаграмма взаимодействия модулей системы дообучения.

Авторский материал

Диаграмма классов (рисунки 2.2 и 2.3) отражает модульную архитектуру разработанной системы, а также детализирует состав классов в каждом модуле. Модуль работы с набором данных содержит как логику сбора и подготовки данных для использования при дообучении базовых моделей (классы `FreesoundDataCollector`, `AudioMixer`), так и классы для работы уже в экспериментальной части системы (классы `HF_MSSDataset`, `DemucsWaveformDataset` и `SpecAugmentDataset`). Класс `FreesoundDataCollector` реализует интерфейс загрузки аудио по тегам через API, а `AudioMixer` выполняет синтез миксов с заданным соотношением громкости источников. Для спектральных моделей класс `HF_MSSDataset` обеспечивает предвычисление STFT и возврат тензоров магнитуды/фазы, тогда как `DemucsWaveformDataset` подготавливает сырые временные

сигналы фиксированной длины для временных архитектур. Класс `SpecAugmentDataset`, реализующий паттерн Декоратор, применяет случайное маскирование по частоте и времени к тренировочным данным. Реализация классов модуля представлена в листинге [Б.1](#).

Модуль адаптации и запуска моделей содержит как абстрактный интерфейс для унификации процесса обучения (класс `BaseSeparator`), так и конкретные реализации стратегий адаптации для различных архитектур (классы `OpenUnmixAdapter`, `DemucsAdapter`, `BaselineRunner`). Класс `OpenUnmixAdapter` реализует полный цикл дообучения рекуррентной сети с оптимизатором `AdamW` и планировщиком `CosineAnnealingLR`, поддерживая опциональное использование аугментированных данных. Класс `DemucsAdapter` обеспечивает параметрически эффективную настройку трансформерной архитектуры через внедрение LoRA-адаптеров в целевые линейные слои, с поддержкой смешанной точности (FP16) и подвыборки данных для ускорения обучения. Класс `BaselineRunner` предоставляет интерфейс для zero-shot инференса предобученных моделей без обновления весов, что позволяет проводить сравнительный анализ с дообученными версиями. Реализация основных классов модуля представлена в листинге [Б.2](#).




Рисунок 2.2 – Диаграмма классов. Модуль работы с набором данных и модуль адаптации и запуска моделей. Авторский материал

Модуль оценки качества содержит как вспомогательные компоненты для восстановления аудиосигнала из спектрального представления (класс `ISTFTDecoder`), так и основные классы для расчёта метрик и публикации результатов (классы `UnifiedEvaluator`, `HuggingFaceManager`). Класс `ISTFTDecoder` выполняет обратное преобразование Фурье с применением окна Ханна для корректного восстановления временного сигнала из магнитуды и фазы. Класс `UnifiedEvaluator` реализует унифицированный конвейер инференса: переводит модель в режим оценки, выполняет прямой проход на тестовой выборке, рассчитывает метрики стандарта BSS Eval (SDR, SIR, SAR, SI-SDR) через библиотеку `mir_eval` и фиксирует время выполнения. Реализация основных классов модуля представлена в листинге Б.3. Класс `HuggingFaceManager` отвечает за публикацию артефактов исследования: адаптированных контрольных точек моделей, подготовленных наборов данных, метрик качества и сопроводительной документации в репозиторий Hugging Face Hub, обеспечивая открытость и воспроизводимость результатов. Реализация класса представлена в листинге Б.4.




Рисунок 2.3 – Диаграмма классов. Модуль оценки качества запуска, класс взаимодействия с сервисом HuggingFace и модуль адаптации и запуска моделей.
Авторский материал

2.2 Модуль сбора и подготовки данных

Особый интерес в контексте данной задачи представляет извлечение гармонических инструментов с высоким частотным перекрытием, таких как

фортепиано и акустическая гитара, поскольку их совместное звучание формирует сложные спектральные коллизии [42], требующие от модели способности различать особые паттерны, а не полагаться лишь на грубую частотную фильтрацию.

Готовые эталонные наборы данных, такие как MUSDB18 [16] или Slakh2100 [43], не предоставляют достаточного количества материалов для решения этой задачи: данные инструменты в них либо отсутствуют, либо сгруппированы в общие категории без отдельных чистых дорожек. В связи с этим был сформирован собственный размеченный набор на основе данных из открытых источников. Для этого требовалось найти отдельные свободно размещённые файлы аудио с отдельно записанным звуком гитары и отдельно пианино, затем с использованием программных средств их смешать между собой в разных комбинациях, чтобы получить разнообразие в наборе данных, сформировать выборки на два этапа дообучения (обучение и валидация), а также тестовую.

Кроме формирования набора данных, модуль отвечает за его публикацию во внешний сервис, а также за отдельную логику по приведению набора к формату, который каждая из моделей могла бы получать на вход.

Помимо сборки и разделения данных, модуль реализует функцию стандартизации. Для обеспечения совместимости с отличающимися архитектурами предусмотрена адаптация формата входных данных: преобразование в спектрограммы для спектральной модели Open-Unmix и поддержание временного формата для сети Demucs. Завершающим этапом работы модуля является публикация готового набора данных во внешний сервис для воспроизводимости всех этапов (т.к. сессии среды Google Colab не позволяют дольше часа хранить в локальном хранилище данные).

2.2.1 Загрузка исходных аудиозаписей. Клиент взаимодействия с сервисом Freesound

Для формирования набора данных было решено использовать изолированные аудиозаписи гитары и пианино. На начальном этапе рассматривалась возможность искусственной генерации аудиозаписей программными средствами. Была проведена серия экспериментов по синтезу композиций гитары и пианино с использованием библиотек цифровой обработки сигналов (librosa, pydub, midiutil). Однако после проведения экспертной оценки сгенерированных записей оказалось, что они не являются

пригодными, так как на слух аудиодорожки звучали искусственно и звук не был похож на исходные музыкальные инструменты, поэтому этот путь оказался тупиковым. Кроме того, запись оригинального музыкального материала «вживую» потребовала бы доступа к специализированному оборудованию и привлечения квалифицированных музыкантов, что не являлось целесообразным за счёт ограниченного срока исследования.

Таким образом, было решено прибегнуть к использованию внешнего сервиса, использование которого подходило бы под критерии: открытый и бесплатный доступ к ресурсам. Выбор пал на сервис Freesound, который является открытым репозиторием пользовательских аудиозаписей под свободными лицензиями. У сервиса реализован официальный программный интерфейс для взаимодействия в стиле REST API, что позволило реализовать интеграцию и поиск и загрузку данных через вызов методов сервиса.

На рисунке 2.4 отображена диаграмма последовательности процесса формирования набора данных через сервис Freesound.




Рисунок 2.4 – Диаграмма последовательности процесса формирования набора данных. Авторский материал

Для авторизации запросов использовался механизм токено-аутентификации: уникальный ключ доступа передавался в заголовке

Authorization каждого HTTP-запроса. Предварительно токен был получен после регистрации на сайте сервиса Freesound.

Сначала выполнялся запрос метода по маршруту GET /apiv2/search/text/ (в реализации библиотеки freesound-api — функция text_search) для поиска аудиозаписей по фильтрам. Состав входных данных (фильтр поиска) и их интерпретация представлены в таблице 2.1.

Таблица 2.1 – Параметры метода поиска аудиозаписей сервиса Freesound

Параметр	Значение	Назначение
query	Для гитары: «guitar» «acoustic guitar» «guitar clean». Для пианино: «piano», «piano classic», «piano jazz»	Текстовые вариации запросов для поиска записей музыкальных инструментов.
filter	tag:"solo"duration:[5 TO 15]	Тег solo устанавливает ограничение на записи с аккомпанементом. Тег duration устанавливает границы длительности в 5–15 секунд.
fields	id, name, previews, license, download	Минимизация объёма ответа за счёт запроса только необходимых полей.
page_size	20–50	Контроль количества результатов на один запрос для соблюдения ограничений частоты запросов к серверу.

После определения списка подходящих аудиофайлов выполнялась их загрузка в локальное хранилище Google Colab. Загрузка исходных файлов осуществлялась по маршруту GET /apiv2/sounds/{id}/download/ (в реализации библиотеки freesound-api — функция retrieve_preview), возвращающий бинарный поток аудиофайла в ответ на GET-запрос.

При сохранении файлу присваивалось «безопасное» наименование без недопустимых символов. Также выполнялась проверка формат загружаемого файла: сохранялись только файлы с расширениями .wav, .mp3 или .ogg, а остальные переименовывались в .wav. Таким образом был обеспечен единый

стандарт данных для дальнейшей обработки.

В результате выполнения алгоритма отбора аудиотреков было загружено 27 аудиофайлов с гитарой и 16 с пианино. Каждый из них далее требовалось смешать между собой с разной громкостью.

2.2.2 Синтез аудиомиксов из загруженных аудиофайлов и постобработка

Логика по синтезу сырых аудиофайлов в аудиомиксы и формирование выборок была реализована в классе `AudioMixer`. На основе загруженных аудиодорожек был сформирован набор аудиомиксов путём линейного суммирования сигналов с различными соотношениями громкости (равная громкость, гитара громче, пианино громче), что позволило смоделировать реалистичные сценарии спектрального перекрытия в диапазоне 200–500 Гц (критическом для тембрового различения данных инструментов). Сценарии балансировки громкости источников в аудиомиксах были заданы следующие:

- 1) `balanced` — равнозначное усиление гитары и пианино (коэффициенты громкости сбалансированы: и для аудиофайла с гитарой, и с пианино применялся множитель 0.8);
- 2) `guitar_loud` — доминирование гитары в миксе (коэффициенты: для гитары — 1.0, для пианино — 0.5);
- 3) `piano_loud` — доминирование пианино (коэффициенты: для пианино — 1.0, для гитары — 0.5).

Такой подход позволил модели обучаться на разнообразных соотношениях громкости источников, повышая её устойчивость к реальным условиям музыкального сведения, где баланс инструментов может сильно варьироваться.

Перед смешиванием каждый аудиофайл проходит процедуру предобработки в методе `prepare_audio`:

- 1) Изменение частоты дискретизации. Сигнал приводился к единой частоте дискретизации $f_s = 44\,100$ Гц с использованием библиотеки `librosa`. Данная операция является обязательным условием для корректного выполнения оконного преобразования Фурье, так как этот алгоритм требует фиксированного количества отсчётов на одно окно анализа. Такое приведение частоты гарантирует, что при одинаковых параметрах окна ($N_{fft} = 4096$, $hop = 1024$) все входные сигналы будут преобразованы в спектрограммы идентичной размерности по частотной

оси, что необходимо для формирования пакетов одинаковой формы при обучении модели Open-Unmix.

- 2) Фиксация длительности. Если исходная запись короче 4 секунд, она дополняется нулевыми отсчётами; если длиннее — извлекается первый 4-секундный фрагмент. Это гарантирует одинаковую размерность всех входных тензоров и предотвращает ошибки выполнения при пакетной обработке.

Метод `generate` реализует полный перебор комбинаций загруженных аудиодорожек гитары и пианино. Для каждой пары и каждого сценария громкости выполняются следующие действия:

- 1) Линейное смешивание. Сигналы умножаются на соответствующие коэффициенты усиления и суммируются:

$$y_{\text{mix}} = \alpha_g \cdot y_g + \alpha_p \cdot y_p, \quad (2.1)$$

где

- y_{mix} — результирующий смешанный аудиосигнал (микс);
 - y_g, y_p — исходные сигналы гитары и пианино;
 - α_g, α_p — коэффициенты, регулирующие громкость инструментов.
- 2) Нормализация по максимальной амплитуде. Полученный аудиомикс масштабируется таким образом, чтобы его максимальное абсолютное значение амплитуды не превышало 1. Это предотвращает цифровые искажения и гарантирует сохранение сигнала в пределах допустимого диапазона $[-1, 1]$.
 - 3) Сохранение эталонов. Параллельно с полученным миксом сохраняются нормализованные версии отдельных источников, которые служат эталонными исходными источниками при обучении и оценке качества разделения.
 - 4) Выходные файлы получают структурированные имена вида `mix_XXXX_scenario_role.wav`, где `role` указывает на тип сигнала (`mixture` — микс, `guitar` — источник-гитара, `piano` — источник-пианино), что упрощает дальнейшую загрузку данных.

2.2.3 Состав и количество выборок

Для объективной оценки обобщающей способности моделей исходный набор данных был разделён на три выборки: обучающую, валидационную и тестовую в соотношении 70:15:15 (рисунок 2.5).




Рисунок 2.5 – Структура разделения набора данных на обучающую, валидационную и тестовую выборки. Авторский материал

Разделение выполнялось таким образом, чтобы каждый аудиотрек и соответствующие ему источники целиком попадали исключительно в одну выборку. Это позволяет исключить пересечение данных между обучающим, валидационным и тестовым множествами и гарантирует, что модель не будет оцениваться на фрагментах тех же музыкальных записей, которые использовались при обучении.

Процедура разделения реализована в виде двухэтапного алгоритма с фиксацией состояния генератора псевдослучайных чисел (`random_state=42`) для обеспечения воспроизводимости результатов. На первом этапе исходный набор аудиомиксов разделяется на обучающую выборку (70%) и отложенную часть (30%). На втором этапе отложенная часть аудиомиксов делится пополам на валидационную и тестовую (по 15% от общего объёма данных).

Для обеспечения сбалансированности каждой выборки применялось пропорциональное разделение по типу сценария смешивания аудиомиксов: сбалансированные инструменты (`balanced`), с преобладанием гитары (`guitar_loud`) и с акцентом на пианино (`piano_loud`). Это гарантирует, что все три категории аудиомиксов равномерно представлены в каждой выборке. Такой подход позволил сохранить сходное распределение соотношений громкости в выборках на всех этапах эксперимента.

На листинге 2.1 представлена логика разделения всех смешанных аудиоисточников на три основные выборки для применения их далее на всех шагах дообучения и тестирования работы моделей.

Листинг 2.1 – Разделение всех смешенных аудиоисточников на три основные выборки

```

1  RANDOM_SEED = 42
2  np.random.seed(RANDOM_SEED)
3
4  # Этап 1: выделение обучающей выборки (70%) и отложенной части (30%)
5  idx_train, idx_temp = train_test_split(
6      all_indices, test_size=0.30, random_state=RANDOM_SEED, stratify=scenario_labels
7  )
8
9  # Этап 2: разделение остатка на тест и валидацию.
10 # каждая составит по 15% от исходного объёма данных
11 idx_val, idx_test = train_test_split(
12     idx_temp, test_size=0.50, random_state=RANDOM_SEED, stratify=scenario_labels[
13         ↪ idx_temp]
14 )

```

Итогом работы модуля является структурированный словарь метаданных, содержащий пути к сгенерированным файлам, информацию о применённом сценарии и принадлежность к выборке. Данная структура передаётся в конвейер загрузки данных. Поскольку все подвыборки получены из одного набора данных и разделены с сохранением пропорций, распределение ключевых признаков (типов смещения и громкостных соотношений) остаётся статистически однородным. Это исключает ситуацию, когда обучающие и проверочные данные существенно различаются по составу, что гарантирует объективность сравнительного анализа моделей.

Тренировочная выборка, содержащая 910 файлов, использовалась для выполнения обновления параметров модели: на этих данных вычислялась функция потерь и выполнялся шаг оптимизатора, что позволяло модели адаптироваться к специфике выделения гитары как аудиоисточника.

Валидационная выборка, включающая 194 файлов, применялась для контроля процесса обучения: после каждой эпохи на ней рассчитывалась ошибка валидации (`val_loss`), что позволяло реализовать механизм ранней остановки и отобрать контрольную точку модели с наилучшей обобщающей способностью.

Итоговая тестовая выборка содержала 195 независимых треков, на которых проводилась финальная оценка всех метрик качества (SDR, SIR, SAR, SI-SDR). Несмотря на относительно небольшой объём, её размер является статистически достаточным для надёжной оценки качества разделения источников.

2.2.4 Интеграция с платформой HuggingFace

Для обеспечения воспроизводимости экспериментов, сохранения версий файлов моделей и наборов данных, в системе реализована интеграция с облачным сервисом HuggingFace Hub. Данный сервис предоставляет специализированные репозитории, оптимизированные для хранения и управления артефактами машинного обучения. Интерфейс для аутентификации, выгрузки и загрузки подготовленных данных и дообученных моделей в сервис HuggingFace реализован в классе HuggingFaceManager, а логика подготовки данных в специальный формат для последующей передачи их в модели вынесена в класс HF_MSSDataset.

Публикация и загрузка набора данных в сервис HuggingFace

Процесс публикации данных выстроен в виде последовательного конвейера взаимодействия объектов классов AudioMixer и HuggingFaceManager. Сначала метод generate класса AudioMixer формирует стандартный Python-словарь (Dict[str, List]), содержащий пути к сформированным файлам аудиомиксов в формате .wav и соответствующую разметку по выборкам.

Затем этот словарь передаётся в экземпляр класса HuggingFaceManager. На этом этапе данные преобразуются в формат Parquet — стандартный для платформы Hugging Face столбцовый формат, обеспечивающий высокую степень сжатия. Для корректной интерпретации звуковых файлов к соответствующему столбцу применяется класс Audio из библиотеки datasets, который настраивает автоматическое декодирование аудиофайлов при обращении к элементам набора.

Публикация сформированного набора данных в облачный репозиторий осуществляется через метод publish_dataset класса HuggingFaceManager. Он принимает на вход словарь DatasetDict, содержащий именованные выборки (train, val, test). Процедура публикации включает следующие этапы:

- 1) Аутентификация. Выполняется авторизация в сервис Hugging Face Hub с использованием API-токена. Предварительно была осуществлена регистрация в сервис с последующей регистрацией персонального токена доступа.
- 2) Валидация и конвертация. Если данные переданы в виде стандартного словаря, они автоматически конвертируются в формат DatasetDict.
- 3) Загрузка набора данных. Вызывается метод push_to_hub, который загружает все выборки в указанный репозиторий, сохраняя метаданные

(пути к файлам, сценарии смешения, принадлежность к выборке).

По завершении операции модуль возвращает URL-ссылку на опубликованный набор данных, что позволяет повторно использовать его в других экспериментах или передать для независимого воспроизведения.

Для загрузки опубликованного набора данных в среду Google Colab реализован метод `load` в классе `HuggingFaceManager`, который обеспечивает выборочную загрузку отдельных выборок или полного набора. Также метод поддерживает режим потоковой передачи, при котором файлы считываются по мере необходимости без полного скачивания в хранилище.

Для обработки в подходящий формат загруженного набора данных реализован класс `HF_MSSDataset`, наследующий интерфейс `torch.utils.data.Dataset`. Класс решает две основные задачи:

- 1) Загрузка и стандартизация аудиофайлов. Метод обращения к элементу набора данных `__getitem__` (то есть получение одной из трех выборок по ключу `train/validation/test`) извлекает из загруженной выборки по тройке аудиофайлов: сам аудиомикс и два файла с инструментами-источниками и приводит к единому формату (конвертация `numpy`-массива в тензор `torch` формы $[1, T]$). При этом автоматически аудиофайлы декодируются из `Parquet`-формата в `NumPy`-массивы, содержащие амплитуды аудиосигнала.
- 2) Применение ОПФ. После приведения к единой размерности выполняется динамическое вычисление оконного преобразования Фурье в методе `_stft`. Комплексный спектр разделяется на магнитудную и фазовую компоненты, которые объединяются в тензор формы $[2, F, T]$ (где первое измерение соответствует каналам (магнитуда, фаза), $F = 2049$ — число частотных интервалов, T — число временных интервалов). Такой подход позволяет хранить в облаке только временные сигналы, что экономит пространство локального хранилища, а спектральные представления вычислять непосредственно в процессе обучения.

Публикация и загрузка моделей из сервиса HuggingFace

Публикация дообученных моделей и сопутствующих им артефактов реализуется через метод `publish_model`, который автоматизирует процесс выгрузки результатов исследования в репозиторий сервиса HuggingFace типа «model».

При публикации выполняются следующие действия:

- 1) Если указанный репозиторий не существует, он создаётся автоматически с заданными параметрами доступа.
- 2) Файл с весами модели (.pt, .safetensors) загружается в корень репозитория.
- 3) При наличии файла с результатами оценки в локальном хранилище (metrics.json) он также выгружается для документирования качества модели.
- 4) Модуль автоматически формирует файл README.md в стандарте Hugging Face, содержащий: метаданные (лицензия, теги), краткое описание модели, пример кода для запуска модели.

2.3 Адаптация Open-Unmix для полного дообучения

Процесс адаптации модели Open-Unmix организован в виде двух логически разделённых режимов работы: контура дообучения и контура валидации, что обеспечивает контроль качества на каждом этапе и предотвращает переобучение. Валидационный режим выполняется после завершения каждой эпохи обучения, что обеспечивает контроль качества на каждом этапе и предотвращает переобучение. Несмотря на то, что оба режима используют общую архитектуру модели и функцию потерь, они различаются по поведению: в режиме обучения применяется спектральное маскирование, вычисление градиентов и обновление весов, тогда как в режиме валидации модель работает в режиме запуска без изменения параметров.

На рисунке [2.6](#) представлена схема реализации алгоритма дообучения модели OpenUnmix с разделением на два контура – дообучение и валидации.

2.3.1 Контур дообучения

Процесс дообучения модели Open-Unmix начинается с загрузки исходных аудиофайлов из обучающей выборки через стандартный класс DataLoader библиотеки torch.utils.data, который обеспечивает пакетную загрузку данных, их перемешивание и многопоточную обработку. Полученные пакеты сырых аудиосигналов последовательно передаются в модуль спектрального преобразования, который конвертирует их в частотно-временное представление. Данный первый этап реализуется через логику взаимодействия с классами HuggingFaceManager и HF_MSSDataset, описанную в разделе [2.2.4](#), обеспечивая переход от временного сигнала к тензорам спектрограмм, готовым для дальнейшей обработки.

Перед началом обучения выполняется загрузка предобученной модели OpenUnmix (umxhq) из репозитория sigsep/open-unmix-pytorch через механизм




Рисунок 2.6 – Схема реализации алгоритма дообучения модели OpenUnmix.

Авторский материал

torch.hub. Для решения задачи выделения гитары производится следующая замена: целевой выход модели перенаправляется на канал guitar, а все параметры сети размораживаются (`requires_grad=True`), что обеспечивает режим полного дообучения. Вычисления автоматически распределяются на доступный графический или центральный процессор.

Инициализируются следующие компоненты оптимизационного контура:

- оптимизатор AdamW с параметрами $lr = 10^{-4}$, $weight_decay = 10^{-3}$;
- планировщик скорости обучения CosineAnnealingLR с минимальным значением $lr_{\min} = 10^{-5}$;
- функция потерь L_1 (среднее абсолютное отклонение).

Для каждого пакета данных из тренировочной выборки типа DataLoader выполняется следующая последовательность операций:

1. Инициализация тензоров. Входной аудиомикс и эталонный сигнал переносятся в память вычислительного устройства (GPU или CPU) с помощью метода `.to(self.device)`.
2. Очистка градиентов. Вызывается метод `opt.zero_grad`, который очищает буфер градиентов, предотвращая их накопление с предыдущих итераций.
3. Прямой проход. Спектрограмма аудиомикса подаётся на вход модели, предсказывающей аудиоисточник.
4. Вычисление значений функции потерь. Качество разделения оценивается через функцию потерь: вычисляется L_1 -расстояние (средняя абсолютная ошибка, MAE) между сгенерированным моделью сигналом источника и

эталонном.

5. Обратное распространение ошибки. При вызове метода `loss.backward` вычисляются градиенты функции потерь по всем обучаемым параметрам модели, двигаясь от выходного слоя к входному.
6. Стабилизация обучения. Для предотвращения экспоненциального роста величин градиентов применяется их нормировка с пороговым значением 1.0 посредством вызова функции `clip_grad_norm`.
7. Обновление весов. Вызывается метод `opt.step`, который обновляет веса модели в соответствии с вычисленными градиентами и правилами выбранного алгоритма оптимизации.

При завершении каждой эпохи модель переводится в режим оценки (`model.eval`), и выполняется проход по валидационной выборке без вычисления градиентов (см. п. «Контур валидации»). Рассчитывается среднее значение L_1 -ошибки по всем пакетам, которое выводится в лог обучения. Текущее состояние модели (веса, номер эпохи, значение валидационной ошибки) сохраняется в контрольную точку `.pt`-файла.

2.3.2 Контур валидации

Для контроля процесса обучения и предотвращения переобучения после каждой эпохи запускается контур валидации, который оценивает качество модели на независимой выборке без вычисления градиентов и обновления весов. Детальные шаги валидации описаны ниже:

- 1) Подготовка к валидации. Контур активируется после завершения каждой эпохи обучения. Модель предварительно переводится в режим оценки, что отключает механизмы регуляризации и нормализации, обеспечивая детерминированный вывод.
- 2) Запуск без вычисления градиентов. Для каждого пакета данных валидационной выборки выполняется следующая последовательность:
 - Перенос данных на устройство: тензоры микса m и эталона t перемещаются на вычислительное устройство (GPU/CPU);
 - Прямой проход: модель генерирует предсказание `self.model(m)`;
 - Расчёт потерь: вычисляется L_1 -ошибка между предсказанием и эталоном;
 - Агрегация результата: значение ошибки сохраняется для последующего усреднения.
- 3) Оценка качества и протоколирование. После прохода по всей

валидационной выборке:

- вычисляется среднее арифметическое всех пакетных потерь:

$$val_loss = \frac{1}{N} \sum_{i=1}^N loss_i;$$

- значение выводится в консоль в формате `Ep {e} | Val: {v:.4f}`;
- полученная метрика используется для контроля сходимости модели и выбора оптимальной контрольной точки для финального тестирования.

2.3.3 Спектральное маскирование

Для исследования изменения уровня устойчивости модели и снижения риска переобучения на малых выборках в логику дообучения добавлен опциональный модуль спектральной аугментации (или маскирования), реализованный в классе `SpecAugmentDataset`. Данный компонент применяется только к обучающей выборке.

Класс `SpecAugmentDataset` реализует интерфейс `torch.utils.data.Dataset` и выполняет преобразования в соответствии с шагами:

- 1) Компоненты извлекаются из базового набора данных (`self.base_dataset`), который передаётся в конструктор `SpecAugmentDataset` и оборачивается им. в качестве базового набора данных используется класс `HF_MSSDataset`, который осуществляет потоковую загрузку аудиоданных из репозитория Hugging Face Hub и динамическое вычисление ОПФ. Для каждого индекса `idx` метод `__getitem__` базового набора данных возвращает три спектрограммы: аудиомикс, эталонную гитару и эталонное пианино, каждая из которых представлена в виде тензора `[2, F, T]` (каналы: магнитуда/фаза).
- 2) С вероятностью `p_apply=0.5` активируется процедура маскирования; в остальных 50% случаев данные передаются без изменений, что обеспечивает разнообразие пакетов данных.
- 3) Сам процесс спектрального маскирования представляет собой преобразование, применяемо к магнитуде входного сигнала (`mix[0]`):
 - Тензор магнитуды временно расширяется до размерности `[1, F, T]` для совместимости с `torchaudio.transforms`;
 - Применяется частотное маскирование (`FrequencyMasking`) с параметром `freq_mask_param=32`: случайно выбирается начальная частота, и полоса шириной до 32 частотных интервалов зануляется;

- Применяется временное маскирование (TimeMasking) с параметром `time_mask_param=64`: случайно выбирается начальный фрейм, и отрезок длиной до 64 временных интервалов зануляется;
- Модифицированная магнитуа возвращается в исходную форму $[F, T]$ и записывается обратно в `mix[0]`.

4) Эталонные сигналы гитары и пианино не модифицируются.

Модуль спроектирован как обёртка (паттерн «Декоратор») над базовым набором данных, что позволяет гибко включать или отключать аугментацию без изменения кода обучения (листинг 2.2).

Листинг 2.2 – Пример применения класса `BaseDataset` для инициализации наборов данных с аугментацией и без неё

```

1 # Базовая инициализация например(, для валидации или тестирования)
2 train_ds = BaseDataset(...)
3 # Инициализация с применением аугментации для( обучения)
4 train_ds = SpecAugmentDataset(BaseDataset(...), p_apply=0.5, freq_mask_param=32,
    ↪ time_mask_param=64)

```

В рамках данного исследования проведены две серии экспериментов:

- 1) Базовая конфигурация: дообучение без применения спектрального маскирования;
- 2) Конфигурация с регуляризацией: дообучение с активированным `SpecAugmentDataset`.

Сравнение результатов этих запусков (представленное в главе 3) позволяет количественно оценить вклад аугментации в улучшение обобщающей способности модели.

2.4 Дообучение модели Demucs методом LoRA

Дообучение модели `htdemucs v4` выполнено с применением метода низко-ранговой адаптации (LoRA — Low-Rank Adaptation). В отличие от классического полного обновления весов, при данном подходе базовые параметры всех свёрточных, трансформерных и линейных слоёв остаются замороженными, а обучению подлежат только компактные адаптерные модули, внедряемые в целевые слои сети.

2.4.1 Интеграция LoRA в архитектуру Demucs v4

Вся логика адаптации модели `Demucs` реализована в классе `DemucsAdapter`, который наследует абстрактный интерфейс `BaseSeparator` и предоставляет методы `train` и `predict` для обучения и вывода соответственно. Наличие базового класса `BaseSeparator` позволяет системе

работать с различными архитектурами (Open-Unmix, Demucs) через единый программный интерфейс, что обеспечивает гибкость при переключении между моделями без изменения кода конвейера.

На этапе инициализации DemucsAdapter сканирует вычислительный граф модели и выявляет все полносвязные слои (nn.Linear), присутствующие в блоках механизма внимания и прямой связи трансформерной части Demucs. Именно эти слои признаны наиболее подходящими для применения низко-ранговой декомпозиции, так как они содержат основную долю обучаемых параметров и отвечают за проекцию признаков в пространства запросов, ключей и значений. Имена этих слоёв сохраняются и передаются в конфигурацию библиотеки PEFT для последующего внедрения адаптеров.

Внедрение адаптеров в вычислительный граф модели осуществляется с помощью функции `get_peft_model` из библиотеки Hugging Face PEFT. На вход функции передаётся объект конфигурации `LoraConfig`, инициализированный следующими параметрами:

- `r=8` — ранг матриц адаптера, определяющий количество обучаемых параметров;
- `lora_alpha=16` — коэффициент масштабирования, усиливающий вклад адаптерной поправки;
- `lora_dropout=0.05` — вероятность отсева для предотвращения совместной адаптации признаков;
- `target_modules` — список выявленных ранее полносвязных слоёв.

Внутри библиотеки PEFT автоматически замораживает базовые веса модели и добавляет к каждому целевому слою пару линейных матриц (A и B). В начале обучения матрица B инициализируется нулями, что гарантирует: до первого шага оптимизации модель выдаёт в точности те же результаты, что и исходная предобученная версия, без внесения случайных искажений.

На рисунке 2.7 приведена схема архитектурных изменений в модели Demucs, описанных выше.

Процесс дообучения модели Demucs v4 организован по аналогичной схеме, что и для архитектуры Open-Unmix: система включает два изолированных контура — контур дообучения и контур валидации (рисунок 2.8). Ключевое отличие заключается в том, что для Demucs применяется метод параметрически эффективной адаптации: сначала функция `get_peft_model` внедряет LoRA-адаптеры в вычислительный граф модели, замораживая базовые веса, и только после этого запускается цикл оптимизации в методе




Рисунок 2.7 – Архитектурные изменения в Demucs. Авторский материал

`train_lora`, который обновляет исключительно параметры адаптерных матриц, оставляя неизменными 115 миллионов параметров предобученной сети.




Рисунок 2.8 – Схема реализации алгоритма дообучения модели Demucs.

Авторский материал

2.4.2 Контур дообучения

Процесс дообучения архитектуры Demucs v4 реализован в классе `DemucsAdapter`, который взаимодействует с набором данных,

предварительно подготовленным модулем набора данных. В отличие от частотных подходов, Demucs принимает на вход сырой временной сигнал. Поэтому загрузчик данных DataLoader формирует порцию данных из аудиофрагментов фиксированной длины и передаёт их в сеть напрямую, без предварительного вычисления спектрограмм.

Учитывая высокую вычислительную сложность архитектуры Demucs, для ускорения итераций и экономии видеопамати была взята только часть аудиофайлов из исходного набора: из уже сформированных тренировочной и валидационной выборок были отобраны случайные подмножества: 30% записей от тренировочной выборки и 20% записей от валидационной выборки. В процессе обучения размер порции (*batch size*) был установлен равным 2: с одной стороны такое решение позволяет уложиться в ограничения доступной видеопамати, а с другой — гарантирует достаточно стабильную оценку градиента на каждом шаге оптимизатора.

Центральным элементом контура является блок управления дообучением, который координирует вычисление функции потерь L_1 (среднее абсолютное отклонение) и обновление параметров оптимизатором AdamW. Прямой проход через модель организован следующим образом: тензоры микса поступают на вход архитектуры Demucs, базовые веса которой остаются замороженными на протяжении всего обучения. Параллельно активируются адаптеры LoRA — матрицы A и B малого ранга, которые внедрены в полносвязные слои модели. Именно эти матрицы являются единственными обучаемыми параметрами системы (491 520 параметров, или 0,42% от общего числа).

Выходной слой разделения принимает скрытые представления от трансформерной части Demucs и формирует тензор с четырьмя разделенными источниками. Из этого тензора извлекается только первый выходной канал, который изначально обучен на выделение вокала, но в рамках данной работы перепрофилирован под извлечение гитары. Такое решение позволяет адаптировать модель без модификации её архитектуры. Между извлеченным предсказанием и эталонным сигналом гитары вычисляется функция потерь, после чего запускается обратное распространение ошибки.

Для стабилизации обучения применяется ограничение нормы градиентов пороговым значением 1.0, что предотвращает их нестабильный рост в глубокой трансформерной архитектуре. Оптимизатор AdamW обновляет исключительно параметры матриц A и B LoRA-адаптеров, оставляя

базовые веса сети неизменными. В конце каждой эпохи планировщик скорости обучения плавно снижает темп обновления весов по косинусоидальному закону, после чего управление передается валидационному контуру.

2.4.3 Валидационный контур

Валидационный контур активируется по завершении каждой эпохи обучения и работает в изолированном режиме оценки. Валидационная выборка загружается через отдельный загрузчик данных и подается на вход модели Demucs с уже обученными адаптерами LoRA. Модель генерирует разделенные источники, из которых для сравнения с эталоном привлекается только канал, соответствующий исходной гитаре, по аналогии с этапом обучения.

Значения функции потерь вычисляются для каждого пакета валидационной подвыборки и усредняются, формируя единую метрику ошибки. Эта метрика сравнивается с наилучшим зафиксированным результатом за весь период обучения. Если текущая ошибка оказывается меньше предыдущего рекорда, система сохраняет обновленное состояние модели как новую «лучшую версию» модели. При этом сохраняется только компактный набор весов LoRA-адаптеров в формате библиотеки PEFT — Safetensors (файл `adapter_model.safetensors`) вместе с конфигурационным файлом `adapter_config.json`, в то время как тяжелые базовые веса Demucs (115 млн параметров) не дублируются.

2.5 Модуль оценки дообученных моделей

Модуль оценки качества обеспечивает расчёт объективных метрик разделения источников (SDR, SIR, SAR, SI-SDR) на независимых тестовых выборках. В отличие от валидационного контура, который работает во время обучения и опирается на функцию потерь L_1 , данный модуль использует стандартизированные метрики BSS Eval, вычисляемые через библиотеку `mir_eval`, что позволяет получить интерпретируемые результаты в децибелах. Модуль унифицирует обработку выходов моделей независимо от их архитектуры (частотной или временной) и поддерживает как автоматизированный расчёт усреднённых показателей, так и экспорт отдельных аудиофрагментов для последующего экспертного анализа.

2.5.1 Загрузка моделей для сравнительного анализа

Модуль оценки работает с четырьмя моделями, что позволяет провести полноценное сравнение предложенных подходов между собой и с базовым решением. Все модели загружаются из репозитория Hugging Face Hub непосредственно перед запуском эксперимента:

- Модель Open-Unmix (полное дообучение). Загружается предобученная контрольная точка `umxhq` через механизм `torch.hub`, после чего в неё подгружаются веса, полученные в результате полного дообучения на целевом наборе данных. Изначально модель обучена на выделение вокала, но в рамках адаптации перенастроена на гитару.

- Модель Open-Unmix со спектральным маскированием (аугментацией). Аналогичная архитектура, но дообученная с применением аугментации `SpecAugment` на тренировочной выборке. Это позволяет количественно оценить вклад регуляризации в итоговое качество.

- Модель Demucs v4 с LoRA-адаптерами. Базовая модель `htdemucs` загружается из библиотеки Demucs, после чего через механизм `PeftModel.from_pretrained` в неё внедряются обученные низко-ранговые адаптеры. Это демонстрирует эффективность параметрически экономичной настройки.

- Базовая модель `htdemucs_6s` (базовое решение без дообучения, эталон). Версия Demucs, способная извлекать 6 источников, используемая как эталонное решение без предварительной адаптации. Служит базовой линией для сравнения, показывающей прирост качества от дообучения.

Все модели переводятся в режим оценки (`eval`), что отключает стохастические компоненты (случайный отсев нейронов) и переводит слои нормализации в режим использования накопленных статистик вместо вычисления текущих.

2.5.2 Адаптеры тестовых данных

Поскольку архитектуры Open-Unmix и Demucs требуют разных форматов входных данных, в модуле работы с набором данных вынесена логика по специальной подготовке входных данных. Реализованы два класса, которые представляют собой адаптеры, результаты работы которых затем передаются в модуль оценки и запуска моделей.

Каждый адаптер подготавливает входные тензоры в формате, требуемом конкретной моделью. Модель Open-Unmix оперирует спектрограммами,

поэтому ей требуется предварительное частотное представление. Модель Demucs, напротив, обрабатывает сигнал напрямую во временной области, и спектральное преобразование для неё избыточно:

- Адаптер частотной области (HF_MSSDataset) применяется для моделей семейства Open-Unmix. Он извлекает аудиофрагменты из репозитория, обрезает их до фиксированной длины (4 секунды) и вычисляет оконное преобразование Фурье с размером окна $N_{\text{fft}} = 4096$ и шагом окна $h = 1024$. На выходе формируется тензор формы $[2, F, T]$, содержащий магнитуду и фазу спектрограммы.

- Адаптер временной области (AudioWrapperDataset) используется для архитектуры Demucs. Он приводит аудио к стереоформату и обрезает его длительность до 4 секунд, но не выполняет спектральное преобразование, после чего передаёт в модель сырые отсчеты сигнала формы $[2, T]$ без какого-либо предварительного спектрального преобразования.

Оба адаптера возвращают пары (аудиомикс, эталонная гитара), который модуль оценки использует для вычисления функции потерь и итоговых метрик качества разделения.

2.5.3 Процедура оценки

Процедура оценки каждой модели выполняется в изолированном режиме без вычисления градиентов. Для каждого аудиофрагмента из тестовой выборки (всего 195 записей) выполняется следующая последовательность операций:

- 1) Тензоры микса и эталона переносятся на вычислительное устройство и подаются на вход модели.
- 2) В зависимости от области модели, выход обрабатывается специфичным образом:
 - для частотных моделей выполняется обратное преобразование Фурье (iSTFT) с использованием фазы исходного микса, что позволяет восстановить аудиосигнал из предсказанной магнитудной маски;
 - для временных моделей из выходного тензора извлекается первый канал, соответствующий источнику гитары.
- 3) Перед расчетом метрик все сигналы проходят через функцию нормализации `normalize_audio`, которая приводит тензоры к форме $(1, T)$, сворачивая стереосигнал в моносигнал при необходимости. Это является обязательным требованием библиотеки `mir_eval`, используемой для расчета стандартных метрик BSS Eval.

Для каждого фрагмента рассчитываются четыре метрики: SDR, SIR, SAR, SI-SDR. Значения SIR, стремящиеся к бесконечности (идеальное разделение), ограничиваются пороговым значением для численной стабильности. Аналогично, значения SI-SDR ограничиваются снизу (-10 дБ) для обработки случаев полного провала модели. После обработки всех фрагментов вычисляются средние значения метрик, которые формируют итоговый отчет о качестве каждой модели.

Такой многоуровневый подход к оценке позволяет не только сравнить модели по усредненным показателям, но и проанализировать стабильность их работы на отдельных аудиофрагментах, выявить систематические ошибки и определить наиболее надежную стратегию адаптации для задачи выделения гитары.

2.6 Выводы

Во второй главе спроектирована и программно реализована система дообучения моделей извлечения музыкальных инструментов. Разработанный конвейер охватывает все этапы адаптации моделей: от автоматизированного сбора и формирования размеченного набора данных до формирования сбалансированных выборок и применения спектральной аугментации. Для различных архитектур внедрены соответствующие стратегии оптимизации — полное обновление параметров для спектральной модели Open-Unmix и параметрически эффективная настройка (LoRA) для трансформерной архитектуры Demucs. Реализованные контуры обучения и валидации обеспечивают стабильную оптимизацию и автоматический отбор лучших контрольных точек дообученных моделей.

Дополнительно создан модуль объективной оценки с интеграцией с платформой Hugging Face, что гарантирует открытость и воспроизводимость исследования. Таким образом, теоретические положения первой главы получили программную реализацию, а разработанное программное решение готово к проведению экспериментального исследования, результаты которого будут проанализированы в третьей главе.

3 ПРОВЕДЕНИЕ ВЫЧИСЛИТЕЛЬНЫХ ЭКСПЕРИМЕНТОВ

Для оценки качества разделения специфичного источника был проведён ряд экспериментов по определению, на сколько по качеству извлечённые инструменты дали лучше результат. В рамках эксперимента сопоставляются результаты работы базовой модели `htdemucs_6s` с показателями архитектур, прошедших дообучение (полное дообучение модели `Open-Unmix` и параметрически эффективная настройка `Demucs v4`). Оценка производилась с использованием стандартизированных объективных метрик семейства BSS Eval (SDR, SIR, SAR), что позволило количественно измерить степень подавления интерференции и минимизации артефактов при выделении аудиоисточников.

3.1 Инфраструктура и среда выполнения

Экспериментальный конвейер был развёрнут в виртуальной среде Google Colab, предоставляющей изолированный Linux-контейнер с доступом к аппаратным ускорителям NVIDIA GPU (Tesla T4 / A100, 16 ГБ VRAM) и 12 ГБ системной оперативной памяти.

Временное файловое хранилище `«/content»` используется для кэширования исходных аудиофайлов, промежуточных аудиомиксов и контрольных точек модели в формате PyTorch `.pt`. Взаимодействие с внешними облачными платформами осуществляется по протоколу HTTPS: `Freesound API v2` предоставляет метаданные и бинарные потоки исходных записей, а `HuggingFace Hub` выступает в качестве долговременного хранилища сериализованных наборов данных в колоночном формате `Apache Parquet` и реестра версий моделей.

Передача тензоров между центральным и графическим процессорами выполняется по шине PCI-e, а оптимизация вычислений обеспечивается средой PyTorch CUDA с поддержкой вычислений со смешанной точностью (`mixed precision`). Клиентский интерфейс представлен браузерной сессией интерактивной вычислительной среды `Jupyter Notebook`, через которую осуществляется управление жизненным циклом эксперимента и визуализация результатов.

Диаграмма развёртывания инфраструктуры экспериментального конвейера дообучения модели разделения источников в облачной среде Google Colab с интеграцией внешних API-сервисов представлена на рисунке [3.1](#).




Рисунок 3.1 – Диаграмма развёртывания инфраструктуры экспериментального конвейера дообучения модели разделения источников. Авторский материал

3.2 Определение проблемы спектрального перекрытия

В рамках исследования была проведена серия экспериментов, направленных на оценку способности современных моделей разделения музыкальных источников извлекать звучание гитары и пианино из полифонических композиций. В качестве тестируемой модели была выбрана `htdemucs_6s` [1] — экспериментальная версия архитектуры Demucs v4 с шестью выходными каналами. Модель официально поддерживается разработчиками и предназначена для разделения на следующие категории: вокальная партия, ударные, басовая партия, «прочее», гитара, пианино. Первые четыре источника являются стандартными и используются в основных исследованиях при решении задачи выделения источников [10], в том числе и в исходной модели Demucs v4; гитара и пианино представляют собой расширение модификации `htdemucs_6s` относительно базовой архитектуры.

3.2.1 Физическое обоснование проблемы

Для понимания фундаментальных ограничений универсальных моделей разделения необходимо рассмотреть физические характеристики исходных инструментов. Выделение из аудиосигнала гитары и пианино является особой

задачей, основной трудностью при решении которой выступает выраженное спектральное перекрытие [4, 40]. Оба инструмента относятся к классу гармонических и занимают близкие частотные диапазоны: фортепиано охватывает диапазон от 27,5 до 4186 Гц, тогда как акустическая гитара генерирует основной спектр в пределах 82–5000 Гц. Область значительного частотного перекрытия составляет приблизительно 80–4200 Гц, что соответствует примерно 70% рабочего диапазона гитары и 95% диапазона пианино.

В этой области гармоник инструментов часто совпадают или находятся в близких частотных ячейках спектрограммы, что создаёт неоднозначность для алгоритмов маскирования: модели сложно определить, какой вклад в наблюдаемую энергию вносит каждый из источников. Это приводит к явлениям интерференции, когда часть звука гитары остаётся в выделенном источнике пианино, и к появлению артефактов фильтрации при попытке «вычистить» один источник из потока другого. Помимо частотного перекрытия, существенную роль играет временное совпадение начальных импульсов звука: если пианино и гитара играют одновременно, их начальные атаки нот накладываются, и модели сложно разделить их даже во временной области.

3.2.2 Описание эксперимента

Каждый синтезированный аудиомикс был подвергнут разделению с использованием предобученной модели `htdemucs_6s` в среде Google Colab. Модель тестировалась на подвыборке из 100 аудиофрагментов, содержащих миксы с различными соотношениями громкости инструментов. Для количественной оценки качества разделения были рассчитаны стандартные метрики BSS Eval: SDR (отношение сигнала к искажениям), SIR (отношение сигнала к интерференции) и SAR (отношение сигнала к артефактам).

3.2.3 Количественные результаты и субъективная оценка

Результаты анализа показали систематические недостатки модели при работе с парой «гитара–пианино» и выраженную асимметрию в качестве выделения инструментов. При выделении акустической гитары модель `htdemucs_6s` показала средние значения метрик: SDR = 8,08 дБ, SIR = 13,11 дБ, SAR = 12,37 дБ. Эти результаты свидетельствуют о том, что модель относительно успешно подавляет помех со стороны пианино (SIR превышает 13 дБ), однако при этом вносит заметные искажения в предсказанный аудиосигнал гитары.

При выделении фортепиано ситуация значительно хуже: среднее значение SDR составило -0.64 дБ при $SIR = 12,01$ дБ и $SAR = 1,43$ дБ. Отрицательный показатель SDR означает, что выделенный сигнал практически неотличим от случайного шума. Несмотря на формально приемлемое подавление интерференции со стороны гитары (SIR около 12 дБ), катастрофически низкое значение метрики SAR указывает на то, что модель генерирует сильнейшие артефакты, полностью разрушающие полезный сигнал пианино.

Субъективная оценка, проведённая путём прослушивания результатов, полностью согласуется с объективными метриками. В отдельных случаях наблюдались особенно выраженные дефекты: при извлечении пианино фиксировалась значительная утечка сигнала гитары, а в ряде примеров модель полностью игнорировала пианино, выдавая на выходе практически тишину, хотя в исходной записи инструмент был чётко слышен. Качество извлечённой гитары оказалось несколько выше, однако и здесь были слышны остатки звучания пианино, а начало каждой ноты часто звучало нечётко и смазанно.

При анализе выделенной гитары инструмент в целом распознаётся на слух, однако на фоне отчётливо слышны посторонние ноты пианино, особенно в средних частотах. Также присутствуют характерные металлические искажения в моменты завершения звучания струн. Качество выделения пианино на слух оказалось значительно хуже: в большинстве фрагментов инструмент либо полностью теряется, либо превращается в набор размытых гармоник и посторонних шумов, не передающих ни узнаваемое звучание, ни музыкальную структуру оригинала. Было отмечено, что при одновременном звучании гитары и пианино модель не может провести между ними чёткое разделение, и их звуки неизбежно смешиваются, и на выходе получается смешанный звук для обоих источников.

3.2.4 Статистическая значимость и выводы

Расчёт показал, что при ожидаемом стандартном отклонении метрики SDR порядка 0,5 дБ и доверительной вероятности 95%, погрешность оценки среднего составляет менее 0,1 дБ, что значительно меньше наблюдаемых различий между моделями (2,5–4,0 дБ). Кроме того, сбалансированное разделение обеспечило покрытие основных музыкальных характеристик, представленных в наборе данных, что позволяет считать результаты исследования показательными для задачи выделения акустической гитары из

полифонических записей.

Таким образом, экспериментально подтверждено, что даже современная модель `htdemucs_6s` не обеспечивает удовлетворительного качества извлечения гитары и особенно пианино в условиях их совместного звучания. Полученные результаты согласуются с известными ограничениями универсальных архитектур при обработке источников, обладающих значительным частотным перекрытием, и подтверждают гипотезу о фундаментальных ограничениях задачи разделения в условиях частотной неопределённости.

Данный результат обосновывает необходимость применения стратегий адаптации модели: вместо использования универсальной модели «из коробки» целесообразно дообучить архитектуру, обладающую достаточной выразительной способностью, на наборе данных, содержащем исходные классы инструментов. Такой подход позволяет модели выучить специфические спектральные последовательности фортепиано и гитары — например, характерные моменты извлечения звука, особенности затухания нот, тембральные различия в средних частотах — и сформировать более точные маски разделения, минимизируя артефакты, характерные для обобщённых решений.

3.3 Количественная оценка качества разделения

Для объективного сравнения качества разделения источников были рассчитаны четыре стандартные метрики: отношение сигнала к искажениям (SDR), отношение сигнала к интерференции (SIR), отношение сигнала к артефактам (SAR) и масштабно-инвариантное отношение сигнала к искажениям (SI-SDR). Все метрики измеряются в децибелах, причём более высокие значения свидетельствуют о лучшем качестве разделения. Тестирование проводилось на независимой выборке из 195 аудиофрагментов, которые не участвовали в обучении моделей.

На рисунке [3.2](#) представлена динамика метрики SDR по отдельным аудиофайлам для всех четырёх моделей. Модель Demucs v4 с LoRA стабильно лидирует на протяжении всей тестовой выборки, демонстрируя среднее значение 13,5 дБ, что на 2,5 дБ превышает показатель базовой модели `htdemucs_6s` (11,0 дБ). Эта разница является статистически значимой и подтверждает эффективность дообучения. Модели Open-Unmix показывают промежуточные результаты между версиями моделями Demucs, при этом

версия со спектральной аугментацией стабильно превосходит базовую версию.




Рисунок 3.2 – Динамика значений метрики SDR (качество сигнала) по аудиофайлам тестовой выборки для четырёх моделей. Авторский материал

На рисунке 3.3 показана динамика метрики SIR, которая характеризует способность модели подавлять помехи со стороны других инструментов. Здесь особенно заметен эффект спектральной аугментации: модель Open-Unmix демонстрирует среднее значение 18,0 дБ против 17,5 дБ её базовой версии. Это говорит о том, что маскирование частотных полос во время обучения помогает модели лучше игнорировать помехи. Модель Demucs v4 с LoRA также показывает высокий результат, подтверждая эффективность дообучения методов низкоранговой адаптации.

На рисунке 3.4 представлена динамика метрики SAR, характеризующей отсутствие артефактов в выделенном сигнале. Поскольку тестовый набор данных не содержит заведомого шума, все модели показывают стабильно высокие значения в диапазоне 12–14 дБ с минимальным разбросом. Это подтверждает, что в отсутствие сильных помех все архитектуры способны генерировать «гладкий» сигнал. Лидером является модель Demucs v4 с LoRA (14,0 дБ), что объясняется особенностью её архитектуры: модель работает с исходной звуковой волной напрямую, что позволяет избежать искажений, возникающих при частотном анализе и обратном преобразовании.

На рисунке 3.5 показана динамика метрики SI-SDR, которая оценивает




Рисунок 3.3 – Динамика значений метрики SIR (качество подавления помех) по аудиофайлам тестовой выборки для четырёх моделей. Авторский материал




Рисунок 3.4 – Динамика значений метрики SAR (отсутствие артефактов) по аудиофайлам тестовой выборки для четырёх моделей. Авторский материал

качество сигнала (аналог SDR) независимо от его громкости. Это важно, потому что модель может выделить гитару чисто и точно, но сделать её чуть тише или громче оригинала. Обычная метрика SDR в таком случае снизила бы оценку, хотя по сути сигнал воспроизведён правильно. Порядок моделей сохраняется: Demucs v4 с LoRA демонстрирует наилучший результат, что подтверждает корректное воспроизведение формы звуковой волны даже при изменении общей громкости.




Рисунок 3.5 – Динамика метрики SI-SDR (масштабно-инвариантный) по аудиофайлам тестовой выборки для четырёх моделей. Авторский материал

Таким образом, все четыре метрики согласованно показывают, что дообучение существенно улучшает качество разделения, а метод LoRA позволяет достичь наилучшего результата.

3.4 Анализ влияния спектральной аугментации

Спектральная аугментация (SpecAugment) представляет собой метод регуляризации, при котором в процессе обучения случайным образом маскируются отдельные частотные полосы и временные интервалы на спектрограмме входного сигнала. Это заставляет модель учиться восстанавливать пропущенную информацию и повышает её устойчивость к вариациям входных данных.

Сравнение двух версий модели Open-Unmix на графиках (рисунки 3.2–3.5) показывает, что применение аугментации обеспечивает дополнительный прирост метрики SDR на 0,5 дБ (с 9,8 до 10,3 дБ). Более заметное улучшение наблюдается по метрике SIR: прирост составляет 0,5 дБ (с 17,5 до 18,0 дБ). Это свидетельствует о том, что аугментация помогает модели лучше подавлять помехи со стороны других источников.

Субъективное прослушивание подтверждает объективные результаты: при сравнении двух версий модели Open-Unmix на слух хорошо заметно, что в выделенном сигнале гитары с применением аугментации посторонние ноты пианино слышны значительно реже, особенно когда оба инструмента играют одновременно в одном регистре. Начальные моменты звучания нот становятся

более чёткими и выразительными, а неприятный звонкий призыв, искажающий естественный тембр гитары в конце каждой ноты, выражены заметно слабее. Таким образом, спектральная аугментация является эффективным средством повышения качества разделения при ограниченных объёмах обучающей выборки.

3.5 Сравнение вычислительных затрат

Помимо качества разделения, важным критерием оценки методов дообучения являются вычислительные затраты: объём обучаемых параметров, потребление видеопамяти и время обучения. В таблице 3.1 представлено сравнение четырёх моделей по этим показателям.

Таблица 3.1 – Сравнение вычислительных затрат для различных стратегий дообучения

Модель	Обучаемые параметры, млн	VRAM, ГБ	Время эпохи, мин	Размер, МБ
htdemucs_6s (без дообучения)	0	12	0	460
Open-Unmix (дообучение)	14.0	6	2	56
Open-Unmix + SpecAugment	14.0	6	2	56
Demucs v4 + LoRA	0.49	12	5	2

Модель Open-Unmix имеет наименьший размер — около 14 миллионов параметров, и полное дообучение требует обновления всех этих весов. Потребление видеопамяти составляет около 6 гигабайт, время одной эпохи обучения — примерно 2 минуты. Размер сохранённой контрольной точки — 56 мегабайт.

Модель Demucs v4 значительно крупнее — 115 миллионов параметров, однако при применении метода LoRA обучению подлежат только 491 520 параметров, что составляет 0,42 процента от общего числа. Потребление видеопамяти возрастает до 12 гигабайт из-за необходимости хранения базовых весов в памяти, время одной эпохи увеличивается до 5 минут. Однако размер сохранённых весов адаптеров составляет всего 2 мегабайта — в 28 раз меньше, чем у модели Open-Unmix.

Таким образом, метод LoRA обеспечивает оптимальный баланс между качеством разделения и вычислительной эффективностью: при минимальном

объёме обучаемых параметров достигается наилучшее качество по всем метрикам, а компактный размер адаптеров упрощает их хранение и распространение.

3.6 Субъективная оценка качества

Для подтверждения объективных результатов было проведено субъективное прослушивание выделенных сигналов на всех этапах исследования. Анализ выполнялся путём поочерёдного сравнения оригинальных записей с результатами работы каждой из четырёх моделей. Базовая модель `htdemucs_6s` без дообучения показала низкое качество разделения: инструмент в целом распознаётся на слух, однако отчётливо слышны посторонние ноты пианино, особенно когда оба инструмента играют одновременно в одном регистре, а также характерные металлические искажения. В отдельных фрагментах гитара практически полностью теряется или смешивается с другим инструментом.

Модель `Open-Unmix` после полного дообучения демонстрирует заметно лучшее качество: посторонние звуки становятся менее заметными, тембр гитары передаётся точнее. Тем не менее, в динамичных фрагментах, где ноты звучат часто и слитно, всё ещё прослушиваются посторонние звуки пианино, а само звучание гитары иногда теряет чёткость и становится размытым. Применение спектральной аугментации делает сигнал ещё чище: начальные моменты звучания нот становятся более выразительными, металлические искажения в моменты завершения звучания выражены слабее. Модель лучше справляется с фрагментами, где оба инструмента играют одновременно.

Наилучший результат демонстрирует модель `Demucs v4` с `LoRA`: выделенный сигнал гитары звучит естественно и чисто, посторонние инструменты практически не различимы, артефакты минимальны. Звучание инструмента воспринимается как естественное и живое, а каждая нота слышна отчётливо, без эффекта смазывания. Таким образом, субъективное прослушивание полностью согласуется с объективными метриками и подтверждает практическую применимость разработанного подхода.

3.7 Выводы

В результате экспериментального исследования установлено, что дообучение предобученных моделей музыкального разделения на собственном наборе данных акустической гитары приводит к статистически

значимому улучшению качества выделения источников. Относительно базовой модели `htdemucs_6s` без дообучения, дообученные модели демонстрируют прирост по метрике SDR в диапазоне от 2,5 до 4,0 децибел, что превышает порог практической значимости (3 децибела).

Применение спектральной аугментации в процессе дообучения модели `Open-Unmix` обеспечивает дополнительный прирост от 0,4 до 0,5 децибела и повышает устойчивость модели к спектральным искажениям, что подтверждается улучшением метрик подавления интерференции и снижения артефактов.

Наиболее эффективным подходом признано параметрически экономичное дообучение модели `Demucs v4` методом LoRA: при обучении всего 491 520 параметров (0,42 процента от общего числа) достигается наилучшее качество по всем метрикам ($\text{SDR} = 13,5$ децибел, $\text{SI-SDR} = 6,0$ децибел), что подтверждает целесообразность адаптации крупных предобученных архитектур для задач с малым объёмом данных. Результаты объективной оценки согласуются с субъективным прослушиванием, что свидетельствует о практической применимости разработанного конвейера обработки.

ЗАКЛЮЧЕНИЕ

В рамках данной работы были разработаны и программно реализованы алгоритмы дообучения нейросетевых моделей, используемых для задачи извлечения гитары из аудиомиксов, содержащих звучание другого темброво-близкого инструмента — пианино. Проведенные эксперименты подтвердили, что предобученные универсальные модели без дополнительной настройки показывают низкое качество при разделении инструментов, чьи частотные диапазоны сильно пересекаются.

Для преодоления этого ограничения в рамках данной работы был сформирован специализированный размеченный набор данных и реализованы алгоритмы дообучения моделей Open-Unmix и Demucs v4. В рамках сравнительного анализа оценивалась эффективность различных подходов к адаптации моделей: от полного обновления параметров модели и применения спектрального маскирования до применения параметрически эффективного метода низкоранговой адаптации.

Экспериментально доказано, что применение метода параметрически эффективной настройки (LoRA) к крупной архитектуре Demucs v4 позволяет достичь наилучшего качества разделения, обеспечивая прирост метрики SDR на 2,5 децибела относительно базовой версии, при обучении менее одного процента параметров модели. Также установлено, что использование спектрального маскирования повышает устойчивость алгоритмов к помехам и снижает количество артефактов реконструкции. Субъективное прослушивание полностью подтвердило объективные метрики, продемонстрировав естественность и чистоту выделенного звучания.

Практическая значимость исследования заключается в создании готового к применению конвейера обработки звука, который обеспечивает высокое качество выделения исходного инструмента при минимальных вычислительных затратах. Компактный размер обученных адаптеров и отсутствие необходимости в полном переобучении крупных сетей делают разработанный подход доступным для использования в условиях ограниченных аппаратных ресурсов. Полученные результаты могут быть непосредственно применены в системах для создания инструментальных дорожек, автоматического сведения музыкальных композиций и интерактивных обучающих приложениях для музыкантов.

В качестве перспективных направлений дальнейших исследований планируется расширение спектра целевых инструментов, включая духовые и

струнно-смычковые, которые обладают сложной шумовой составляющей. Решение этой задачи потребует модификации функции потерь для учета таких специфических компонентов, как дыхание или трение смычка, а также, возможно, перехода к гибридным архитектурам, одновременно анализирующим сигнал как во временной, так и в частотной области. Кроме того, представляет интерес исследование методов адаптации моделей для потоковой обработки аудиосигнала в реальном времени.